[DERS KODU] – Data Mining
Şube: [ŞUBE]

Vize Projesi (Midterm Project)

İstanbul Airbnb İlanlarında Fiyatı Etkileyen Faktörler: Doğrusal ve İkili Lojistik Regresyon Analizi

Teslim Tarihi: [TESLİM TARİHİ]

Hazırlayanlar:
[AD SOYAD 1]
[AD SOYAD 2]

1. Giriş

Kısa dönem konaklama platformlarında bir ilanın gecelik fiyatı; mekânın büyüklüğüne, kiralanan alanın türüne ve ev sahibinin platformdaki itibarına göre değişir. Bu projede Inside Airbnb'nin yayımladığı İstanbul ilan verisiyle (Inside Airbnb, 2026) gecelik fiyatı etkileyen faktörler incelenmiştir.

Projenin amacı, gerçek bir veri seti üzerinde veri ön işleme, doğrusal regresyon ve ikili lojistik regresyonu RStudio'da, R programlama diliyle (R Core Team, 2024) uygulamaktır.

İlk aşamada ham verideki tip hataları, eksik değerler, tutarsız kategoriler, uç değerler ve olası veri giriş hataları tespit edilmiş ve her biri gerekçeli bir kararla giderilmiştir. İkinci aşamada sayısal bağımlı değişken olan gecelik fiyat (`price`, TL) önce tek bir sayısal değişkenle (basit doğrusal regresyon), sonra sayısal ve kategorik değişkenleri birlikte içeren bir modelle (çoklu doğrusal regresyon) açıklanmıştır. Üçüncü aşamada fiyat, medyan eşiğine göre "yüksek fiyatlı" ve "düşük/orta fiyatlı" olarak ikiye ayrılmıştır. Bir ilanın yüksek fiyatlı olma odds'u dört lojistik modelle incelenmiş, modellerin uyumu ve sınıflandırma başarısı değerlendirilmiştir.

Bütün analizlerde aynı temizlenmiş veri seti ve aynı temel bağımlı değişken (`price`) kullanılmıştır. Lojistik regresyonda kullanılan ikili değişken, doğrusal regresyondaki sayısal fiyattan türetilmiştir.

2. Veri Seti Tanımı

2.1. Veri kaynağı

Çalışmada Inside Airbnb'nin İstanbul (Marmara, Turkey) için yayımladığı "Detailed Listings data" dosyası (`listings.csv.gz`) kullanılmıştır. Dosya 25 Eylül 2026 tarihli veri yayınına aittir; veriler 28–29 Eylül 2026′da toplanmıştır. Veri https://insideairbnb.com/get-the-data/ adresinde Creative Commons lisansıyla paylaşılmaktadır (Inside Airbnb, 2026). Her satır İstanbul'daki bir Airbnb ilanıdır.

2.2. Gözlem ve değişken sayısı

Ham veride 27.232 gözlem (ilan) ve 90 değişken vardır. Analizde kullanılmayan sütunlar çıkarılıp Bölüm 3.3′teki satır filtreleri uygulandıktan sonra temiz veride 16.303 gözlem ve 10 değişken kalmıştır.

Temiz veri seti yönergenin 1.1 maddesindeki bütün şartları karşılar:

- En az 100 gözlem: 16.303 gözlem.
- En az 4 sayısal değişken: 6 sayısal değişken (`price`, `accommodates`, `bedrooms`, `bathrooms`, `number_of_reviews`, `availability_365`).
- En az 3 kategorik değişken: `host_is_superhost`, `room_type` ve `shared_bath`. Bağımlı değişken olan `high_price` bu sayıya dahil edilmemiştir.
- En az bir iki kategorili bağımsız değişken: `host_is_superhost` ve `shared_bath`.

• En az bir 3+ kategorili bağımsız değişken: `room_type` (4 kategori).

2.3. Değişken açıklama tablosu

Tablo 1, temizlenmiş veri setindeki değişkenlerin türünü, analizdeki rolünü, kaynağını ve değer aralığını gösterir. Veri setinde iki bağımlı değişken, beş sayısal ve üç kategorik bağımsız değişken vardır.

Tablo 1. Temizlenmiş veri setindeki değişkenler

Değişken	Tür	Rol	Açıklama	Kaynak	Aralık / Düzeyler (n)
price	Sayısal (sürekli)	Bağımlı değişken (doğrusal regresyon)	İlanın gecelik fiyatı (TL)	Ham price, metinden sayıya çevrildi	542 – 38.286,33
high_price	Kategorik (ikili, 0/1)	Bağımlı değişken (lojistik regresyon)	1 = fiyat > medyan (4.457,5 TL); 0 = fiyat ≤ medyan	price'tan türetildi	0 (8.162); 1 (8.141)
accommodates	Sayısal (kesikli)	Bağımsız	Ağırlanabilecek en fazla misafir sayısı	Ham	1 – 16
bedrooms	Sayısal (kesikli)	Bağımsız	Yatak odası sayısı	Ham	0 – 15
bathrooms	Sayısal	Bağımsız	Banyo sayısı (yarım banyo = 0,5)	bathrooms_ text'ten türetildi	0 – 15
number_ of_reviews	Sayısal (kesikli)	Bağımsız	Alınan toplam yorum sayısı	Ham	0 – 1.862
availability_ 365	Sayısal (kesikli)	Bağımsız	Önümüzdeki 365 gün içinde müsait gün sayısı	Ham	0 – 365
host_is_ superhost	Kategorik (ikili)	Bağımsız	Ev sahibinin Superhost statüsü (referans: No)	Ham (t/f), No/Yes olarak kodlandı	No (10.827); Yes (5.476)
room_type	Kategorik (4 kategori)	Bağımsız	Kiralanan alanın türü (referans: Entire home/apt)	Ham	Entire home/apt (11.777); Private room (4.172); Hotel room (228); Shared room (126)
shared_ bath	Kategorik (ikili)	Bağımsız	Banyonun paylaşımlı olup olmadığı (referans: No)	bathrooms_ text'ten türetildi	No (15.645); Yes (658)

2.4. Sayısal bağımlı değişken

Doğrusal regresyonun bağımlı değişkeni ilanın gecelik fiyatı olan `price` değişkenidir. Ham veride bu değişken `"$4,736.32"` biçiminde metin olarak saklanır. Değerlerin önünde `$` işareti olsa da birim Türk Lirasıdır. Temizlenmiş veride fiyat 542 TL ile 38.286 TL arasındadır; med-

yanı 4.457,5 TL, ortalaması 5.679,73 TL'dir. Ortalamanın medyandan büyük olması dağılımın sağa çarpık olduğunu gösterir.

2.5. İkili bağımlı değişkenin oluşturulması

Lojistik regresyon için `price` değişkeninden `high_price` adlı ikili bir değişken türetilmiştir:

$$high_price = \begin{cases} 1 \text{ price} > 4457,5 \text{ TL (hedef sonuç: yüksek fiyat)} \\ 0 \text{ price} \leq 4457,5 \text{ TL (referans sonuç: düşük/orta fiyat)} \end{cases}$$

Eşiğin gerekçesi. Eşik olarak temizlenmiş verideki fiyat medyanı (4.457,5 TL) seçilmiştir. Medyan veriyi neredeyse eşit iki gruba ayırır; böylece bir sınıfın baskın olması sınıflandırma başarısını yanıltıcı biçimde yükseltmez. Fiyat dağılımı sağa çarpık olduğu için ortalama (5.679,73 TL) uç değerlerden etkilenir, medyan ise etkilenmez. Ayrıca medyan doğrudan veriden hesaplanır ve araştırmacının keyfi olarak seçtiği bir TL değerine dayanmaz. Yönerge de medyanı kabul edilebilir eşikler arasında sayar.

`high_price = 1` olan bir ilan, İstanbul'daki kısa dönem ilanları arasında fiyat bakımından üst yarıdadır. Eşik, bütün temizleme adımları bittikten sonra son veri üzerinden hesaplanmıştır. Sınıf dağılımı Tablo 2'dedir.

Tablo 2. İkili bağımlı değişkenin (high_price) dağılımı

high_price	Anlam	Gözlem sayısı	Yüzde
0	Düşük/orta fiyat (referans)	8.162	%50,06
1	Yüksek fiyat (hedef)	8.141	%49,94
Toplam		**16.303**	**%100**

İki sınıf neredeyse eşit büyüklüktedir. Değişkenin doğru oluşturulduğu üç kontrolle doğrulanmıştır:

- 0 grubundaki fiyatlar 542 – 4.457,5 TL, 1 grubundaki fiyatlar 4.458 – 38.286,33 TL aralığındadır. 0 grubunun en yüksek fiyatı medyanı aşmaz, 1 grubunun en düşük fiyatı ise medyanın üzerindedir.
- Değişken yalnızca 0 ve 1 değerlerini almaktadır ve eksik değer içermemektedir.
- Kural bağımsız olarak yeniden hesaplandığında bütün satırlarda aynı sonuç elde edilmiştir.

Gruplar tam %50'ye %50 değildir, çünkü fiyatı tam medyana eşit olan 11 ilan "büyüktür" kuralı gereği 0 grubuna düşmüştür. Orijinal `price` değişkeni, kendi ikili dönüşümünü tahmin etmek için hiçbir lojistik modelde bağımsız değişken olarak kullanılmamıştır.

```
price_median <- median(df$price)
df <- df %>% mutate(high_price = if_else(price > price_median, 1L, 0L))
```

3. Veri Keşfi ve Ön İşleme

3.1. Verinin RStudio'ya aktarılması

Ham veri dosyası, gzip ile sıkıştırılmış bir CSV (virgülle ayrılmış değerler) dosyasıdır (`.csv.gz`). Dosya, tidyverse paket koleksiyonundaki (Wickham et al., 2019) `readr` paketinin `read_csv()` fonksiyonuyla önceden açılmadan doğrudan okunmuştur. Sütun tiplerini güvenilir biçimde tahmin edebilmesi için fonksiyona bütün satırlara bakması söylenmiştir (`guess_max = 30000`). Okuma sırasında hiçbir ayrıştırma (parsing) hatası oluşmamıştır.

```
library(tidyverse)
listings <- read_csv("data/listings.csv.gz", guess_max = 30000, show_col_types =
FALSE)
dim(listings)   # 27232 90
```

Dosya formatı gzip ile sıkıştırılmış CSV (`.csv.gz`), kullanılan R fonksiyonu `readr::read_csv()`'dir. Veride 27.232 gözlem ve 90 değişken vardır.

3.2. İlk inceleme ve tespit edilen sorunlar

Veri seti önce `head()`, `dim()`, `str()` ve `summary()` fonksiyonlarıyla incelenmiştir:

- `head()`: Her satırın bir ilan olduğunu ve `price` değişkeninin `"$4,736.32"` gibi metin olarak saklandığını göstermiştir.
- `dim()`: Verinin 27.232 satır ve 90 sütundan oluştuğunu doğrulamıştır.
- `str()`: 47 sayısal, 20 metin (character), 17 mantıksal (logical) ve 6 tarih (Date) tipinde değişken bulunduğunu göstermiştir.
- `summary()`: Sayısal değişkenlerin dağılımını ve eksik değer sayılarını ortaya koymuştur.

Bulunan sorunlar Tablo 3'te özetlenmiştir.

Tablo 3. İlk incelemede tespit edilen veri sorunları

Sorun türü	Sorun	Değişken	Satır sayısı	Örnek
Yanlış veri tipi	Sayı, metin olarak saklanmış ($ ve virgül)	price	24.553	"$4,736.32"
Yanlış veri tipi	Tamamen boş sütun (mantıksal okundu, tümü NA)	13 sütun (ör. bathrooms, instant_bookable, host_since)	27.232	(tüm değerler boş)
Yanlış veri tipi	Banyo sayısı yalnızca metin içinde	bathrooms_text	27.121	"1.5 shared baths"
Eksik değer	Eksik fiyat	price	2.679	(boş hücre)
Eksik değer	Hiç yorum almamış ilanlarda eksik puan	review_scores_ rating	9.661	(boş hücre)
Eksik değer	Hiç yorum almamış ilanlarda eksik değer	reviews_per_ month	9.661	(boş hücre)

Sorun türü	Sorun	Değişken	Satır sayısı	Örnek
Eksik değer	Eksik değer	beds	413	(boş hücre)
Eksik değer	Eksik değer	bathrooms_text	111	(boş hücre)
Eksik değer	Eksik değer	bedrooms	23	(boş hücre)
Tutarsız kategori	Sayı içermeyen banyo metinleri	bathrooms_text	157	Half-bath / No bathroom / Private half-bath / Shared half-bath
Tutarsız kategori	Çok küçük kategoriler	room_type	430	Hotel room (272), Shared room (158)
Tutarsız kategori	Çok sayıda kategori (39 ilçe)	neighbourhood_cleansed	27.232	Beyoğlu 7.447 … en küçük ilçeler < 20
Tutarsız kategori	Çok sayıda / çok küçük kategori (88 düzey)	property_type	440	88 düzey
Tutarsız kategori	Karışık serbest metin biçimleri	license	17.703	34-1476 / Exempt / Non-real estate listing
Olağandışı değer	Uç değer (Q3 + 1,5×IQR üstü)	price	1.656	4.989.148,47
Olağandışı değer	Şüpheli sık değer (muhtemelen aylık kiralık)	minimum_nights	9.087	100
Olağandışı değer	Uç değer (365 geceden fazla)	minimum_nights	14	1.000
Olağandışı değer	Uç değer	bedrooms / beds	37	bedrooms maks. 50, beds maks. 67
Giriş hatası	Geçersiz değer (ölçek 1–5)	review_scores_rating	1	0
Giriş hatası	Misafir sayısından fazla yatak odası	bedrooms – accommodates	241	5 yatak odası, 2 misafir
Giriş hatası	Misafir başına 2′den fazla yatak	beds – accommodates	177	8 yatak, 2 misafir
Giriş hatası	Airbnb üst sınırının (1.125) aşılması	maximum_nights	5	7.000
Giriş hatası	Bütün ev/daire olup 0 banyo	bathrooms_text	89	Entire home/apt, 0 baths

Yanlış veri tipleri

- `price` metin olarak saklandığından sayısal işlemlerde kullanılamamaktadır.
- 13 sütun tamamen boştur. `read_csv()` bu sütunların tipini tahmin edemediği için onları mantıksal (logical) okumuştur.
- Banyo sayısı, sayısal bir sütun yerine yalnızca `"1.5 shared baths"` gibi metinlerde yer almaktadır.

- `host_is_superhost` değişkeni ham dosyada `t`/`f` olarak yazılıdır. `read_csv()` onu doğrudan mantıksal tipe çevirdiği için burada tip sorunu yoktur.

Eksik değerler

- Eksik fiyatlar bağımlı değişkende yer aldığından ilgili ilanlar regresyonda kullanılamaz.
- Eksik puanların (9.661) tamamı hiç yorum almamış (`number_of_reviews = 0`) ilanlara aittir. Puanın boş olmasının nedeni yorum bulunmamasıdır, yani bu eksiklik yapısaldır.

Olağandışı sayısal değerler

- Fiyat dağılımı aşırı sağa çarpıktır: medyan 3.710 TL, %99′luk dilim 38.317,80 TL, maksimum ise yaklaşık 4,99 milyon TL'dir.
- `minimum_nights` değişkeninde 100 değeri en sık görülen ikinci değerdir (9.087 ilan). Bu yığılma, verinin önemli bir kısmının aylık/uzun dönem kiralık ilan olduğunu düşündürür.

Olası veri giriş hataları

- Misafir sayısından fazla yatak odası olan ilanlar ve banyosuz "bütün ev/daire" ilanları mantıksal olarak tutarsız olduğu için olası veri giriş hatası sayılmıştır.

3.3. Veri temizleme ve hazırlama

Ham dosya hiçbir aşamada değiştirilmemiş, bütün düzeltmeler R kodu içinde yapılmıştır. Uygulanan adımlar ve her adımdan önceki ve sonraki satır sayıları Tablo 4′tedir.

Tablo 4. Temizleme adımları ve satır sayıları

Adım	İşlem	Önce	Sonra	Çıkarılan
1	Yalnızca kullanılacak değişkenleri tutma (sütun işlemi)	27.232	27.232	0
2	price değişkenini metinden sayıya çevirme	–	–	–
3	Eksik fiyatlı ilanları çıkarma	27.232	24.553	2.679
4	%1 – %99 persentil dışındaki fiyatları çıkarma	24.553	24.065	488
5	minimum_nights > 30 olan ilanları çıkarma	24.065	16.493	7.572
6	bathrooms_text'ten bathrooms ve shared_bath türetme	–	–	–
7a	bedrooms > accommodates olan ilanları çıkarma	16.493	16.454	39
7b	Banyo sayısı 0 olan "Entire home/apt" ilanlarını çıkarma	16.454	16.399	55
7c	bathrooms > accommodates olan ilanları çıkarma	16.399	16.371	28
8	Eksik bedrooms / bathrooms içeren satırları çıkarma	16.371	16.303	68
9	Kategorik değişkenleri factor'e çevirme ve referansları belirleme	–	–	–

Sonuçta ham verinin %59,9′u (16.303 ilan) analizde kullanılmıştır.

Adım 1: Değişken seçimi. Analizde kullanılacak değişkenler tutulmuş, diğerleri çıkarılmıştır. Çıkarılan sütunlar arasında URL'ler, serbest metinler, 13 tamamen boş sütun, lisans bilgisi ve puan alt boyutları yer almaktadır.

- `minimum_nights` Adım 5'teki filtre için, `bathrooms_text` ise Adım 6'daki dönüşüm için geçici olarak tutulmuştur.
- Bu seçimle Tablo 3'teki bazı sorunlar kendiliğinden ortadan kalkmıştır, çünkü ilgili değişkenler analizde kullanılmamaktadır: boş sütunlar, `beds` değişkenindeki eksik ve uç değerler, `maximum_nights` sınır aşımı, `property_type` ve `license` karmaşası.
- `review_scores_rating` modele alınmamıştır. İlanların %35,5'inde (9.661 ilan) eksik olan bu değişken kullanılsaydı, hiç yorum almamış ilanların tamamının analiz dışında kalması gerekecekti. Eksik puanları doldurmak ise "yorum almamış ilanın puanı olmaz" gerçeğiyle çelişen yapay değerler üretecekti. Değişken çıkarılınca tek geçersiz puan değeri (0) sorunu da ortadan kalkmıştır.

Adım 2: Tip dönüşümü. `price` değişkeni `parse_number()` fonksiyonuyla sayıya çevrilmiştir. Fonksiyon `$` işaretini ve binlik ayıracı kaldırmaktadır (`"$4,736.32"` → 4736,32).

Adım 3: Eksik fiyatlar. Fiyatı eksik 2.679 ilan çıkarılmıştır. Bağımlı değişkeni ortalama veya medyan gibi bir değerle doldurmak yapay veri üreteceği için bu ilanlar silinmiştir.

Adım 4: Fiyat uç değerleri. Eksik fiyatlar çıkarıldıktan sonra fiyatın %1 persentili (417,28 TL) ve %99 persentili (38.317,80 TL) hesaplanmış; bu aralığın dışında kalan 488 ilan çıkarılmıştır.

- Doğrusal regresyonda kullanılan en küçük kareler yöntemi uç değerlere çok duyarlıdır. Milyonlarca TL'lik birkaç değer, regresyon doğrusunu kendine doğru çekerek katsayıları yanıltıcı hâle getirebilir.
- Persentil kuralı sınırı dağılımın kendisinden alır ve iki uçtaki aşırı değerleri simetrik biçimde ayıklar. Bu yüzden keyfi bir TL sınırından daha nesneldir.

Adım 5: Uzun dönem kiralıklar. 30 geceden uzun konaklama şartı koyan (`minimum_nights > 30`) 7.572 ilan çıkarılmış, ardından `minimum_nights` değişkeni de veriden silinmiştir. Bu ilanlar fiilen aylık ya da uzun dönem kiralıktır ve "gecelik fiyatları" kısa dönem konaklama ilanlarıyla karşılaştırılamaz. Bu adım, ilk incelemede görülen 100 gecelik yığılmayı da temizlemiştir. Analiz böylece en fazla 30 gecelik konaklama şartı olan kısa dönem ilanlarla sınırlanmıştır.

Adım 6: Yeni değişkenler. `bathrooms_text` metninden iki yeni değişken türetilmiştir.

- `bathrooms` (sayısal):
  - Metinde bir sayı varsa o sayı alınmıştır ("1.5 shared baths" → 1,5).
  - Sayı içermeyen "Half-bath", "Private half-bath" ve "Shared half-bath" değerleri 0,5 olarak kodlanmıştır.
  - "No bathroom" değeri 0 olarak kodlanmıştır; bu değere sahip ilanlar önceki adımlarda zaten çıkmıştır.

- `shared_bath` (iki kategorili): Metinde “shared” ifadesi geçiyorsa “Yes”, geçmiyorsa “No” değerini almıştır. Bu değişken, yönergenin istediği üçüncü kategorik değişkendir.

Adım 7: Veri giriş hataları. Mantıksal olarak tutarsız üç durum veri giriş hatası kabul edilmiştir.

- 7a: Misafir sayısından fazla yatak odası bulunan 39 ilan çıkarılmıştır (ör. 2 misafirlik 5 yatak odası).
- 7b: Bütün bir evin veya dairenin banyosuz olması mümkün olmadığından banyo sayısı 0 olan 55 “Entire home/apt” ilanı çıkarılmıştır.
- 7c: Aynı mantıkla banyo sayısı misafir sayısını aşan 28 ilan çıkarılmıştır. Bu ilanlarda, örneğin 2 kişilik bir özel oda için 34 banyo gibi değerlerin bir otel veya hostel binasının toplam banyo sayısının tek bir ilana yazılmasından kaynaklandığı düşünülmektedir. Bu kuraldan sonra banyo sayısının maksimumu 15′e inmiştir.
- Banyo sayısı 0 olan oda ilanları (Private, Shared, Hotel room) veride tutulmuştur. Bu ilanlarda 0, odaya ait banyo olmadığını ve ortak bir banyonun kullanıldığını gösterir. 0 banyo yalnızca “Entire home/apt” ilanlarında hata kabul edilmiştir.

Adım 8: Kalan eksik değerler. `bedrooms` veya `bathrooms` değişkeni eksik olan 68 satır çıkarılmıştır. Bu satırlar örneklemin çok küçük bir bölümü olduğu için silmek örneklem büyüklüğünü pek etkilemez ve yapay değer üretmekten daha uygundur.

Adım 9: Kategorik değişkenlerin yeniden kodlanması. Kategorik değişkenler factor’e çevrilmiş ve her birinin ilk düzeyi referans kategori olarak belirlenmiştir:

- `host_is_superhost`: TRUE/FALSE değerleri “Yes”/“No” olarak yeniden kodlanmıştır; referans kategori “No” (Superhost değil).
- `room_type`: referans kategori “Entire home/apt”. Bu kategori en büyük grup olduğu için seçilmiştir.
- `shared_bath`: referans kategori “No” (özel banyo).

Bu referans kategoriler bütün doğrusal ve lojistik modellerde aynı şekilde kullanılmıştır.

Temizleme sürecinin temel kod satırları aşağıda verilmiştir; kodun tamamı Ek’tedir.

```
df <- df %>% mutate(price = parse_number(price))                  # metin -> sayi
df <- df %>% filter(!is.na(price))                                 # eksik fiyat
p01 <- quantile(df$price, 0.01); p99 <- quantile(df$price, 0.99)
df <- df %>% filter(price >= p01, price <= p99)                    # %1 - %99
df <- df %>% filter(minimum_nights <= 30) %>% select(-minimum_nights)
df <- df %>% filter(is.na(bedrooms) | bedrooms <= accommodates)   # giris hatasi
df <- df %>% filter(!(room_type == "Entire home/apt" & !is.na(bathrooms) &
bathrooms == 0))
df <- df %>% filter(is.na(bathrooms) | bathrooms <= accommodates) # giris hatasi
df <- df %>% filter(!is.na(bedrooms), !is.na(bathrooms))          # kalan eksikler
```

3.4. Son veri setinin doğrulanması

Temizleme ve değişken oluşturma işlemlerinden sonra veri seti `str()`, `summary()` ve `dim()` fonksiyonlarıyla yeniden incelenmiştir.

- `dim()`: Son veri seti 16.303 gözlem ve 10 değişkenden oluşur ve hiç eksik değer içermez.
- `str()`: Değişken tipleri amaca uygundur. Altı değişken sayısal (numeric), üç değişken factor, `high_price` ise 0/1 değerli tamsayıdır.

Sayısal değişkenlerin özet istatistikleri Tablo 5′te verilmiştir.

Tablo 5. Son veri setindeki sayısal değişkenlerin özet istatistikleri (summary() çıktısı)

Değişken	Min.	1. Çeyrek	Medyan	Ortalama	3. Çeyrek	Maks.
price (TL)	542	3.000	4.458	5.680	6.744	38.286
accommodates	1	2	3	3,708	4	16
bedrooms	0	1	1	1,427	2	15
bathrooms	0	1	1	1,179	1	15
number_of_ reviews	0	1	9	33,87	41	1.862
availability_365	0	255	342	289,9	362	365

Veri seti aşağıdaki nedenlerle regresyon analizlerine hazırdır:

- Eksik değer yoktur.
- Değişken tipleri doğrudur ve kategorik değişkenlerin referans kategorileri tanımlıdır.
- Mantıksız girişler ve aşırı fiyatlar ayıklanmıştır.
- Doğrusal regresyon için sayısal bağımlı değişken (`price`), lojistik regresyon için ondan türetilen ikili bağımlı değişken (`high_price`) hazırdır.

Bununla birlikte bazı özellikler yorumlarda göz önünde tutulmuştur:

- `price` hâlâ sağa çarpıktır (ortalama > medyan).
- `number_of_reviews` çok çarpıktır (medyan 9, maksimum 1.862).
- Hotel room (228), Shared room (126) ve `shared_bath = Yes` (658) grupları küçüktür.

4. Doğrusal Regresyon Sonuçları

4.1. Basit doğrusal regresyon

Değişkenler ve seçim gerekçesi. Bağımlı değişken (Y) `price` (gecelik fiyat, TL), bağımsız değişken (X) `accommodates`'tir (ilanın ağırlayabileceği en fazla misafir sayısı). Daha fazla misafir ağırlayabilen bir mekânın daha pahalı olması beklenir. Değişkende eksik değer yoktur ve fiyatla orta-güçlü, pozitif bir doğrusal ilişkisi vardır (r = 0,5319). Medyan fiyat da kapasiteyle düzenli olarak artar: 1 kişilik ilanlarda 2.040 TL, 2 kişilik ilanlarda 3.100 TL, 4 kişilik ilanlarda 5.016 TL ve 6 kişilik ilanlarda 7.245 TL.

Model şu şekildedir:

$$price = \beta_0 + \beta_1 \cdot accommodates + \varepsilon$$

Model R'da `lm(price ~ accommodates, data = listings)` komutuyla tahmin edilmiş, sonuçlar Tablo 6′da verilmiştir.

Tablo 6. Basit doğrusal regresyon sonuçları (Y = price)

Terim	B	Std. hata	t	p
(Sabit)	1.789,30	56,38	31,74	< 0,001
accommodates	1.049,31	13,08	80,20	< 0,001
Model istatistikleri				
F (1; 16.301)	6.431,74			< 0,001
R^2	0,2829			
Düzeltilmiş R^2	0,2829			

Not: n = 16.303. Artıkların standart hatası 3.668 TL.

Modelin genel anlamlılığı. F testinin hipotezleri şunlardır:

- H_0: Model fiyatı açıklamamaktadır ($\beta_1 = 0$).
- H_1: Model fiyatı açıklamaktadır ($\beta_1 \neq 0$).

F(1; 16.301) = 6.431,74 ve p < 0,001 olduğundan H_0 reddedilir; model istatistiksel olarak anlamlıdır.

Bağımsız değişkenin anlamlılığı. `accommodates` için t = 80,20 ve p < 0,001 bulunmuştur. Kapasitenin fiyata etkisi olmadığını öne süren H_0 reddedilir, yani `accommodates` anlamlı bir açıklayıcı değişkendir.

Katsayının yorumu. B_1 = 1.049,31′dir: ilanın kapasitesi bir kişi arttığında gecelik fiyat ortalama yaklaşık 1.049 TL artar. Pozitif işaret kuramsal beklentiyle uyumludur. Sabit terim (B_0 = 1.789,30), kapasitenin 0 olduğu durumdaki tahmini fiyattır; veride 0 kişilik ilan olmadığı için pratik bir anlamı yoktur.

Tahmini regresyon denklemi:

$$\widehat{price} = 1789,30 + 1049,31 \times accommodates$$

R^2 ve düzeltilmiş R^2. R^2 = 0,2829′dur, yani fiyattaki değişkenliğin %28,3′ü tek başına kişi kapasitesiyle açıklanır. Kalan değişkenlik modelde olmayan etkenlerden (ör. konum, oda tipi, mekânın niteliği) gelir. Modelde tek bir bağımsız değişken olduğu ve gözlem sayısı çok yüksek olduğu için düzeltilmiş R^2 (0,2829) R^2 ile neredeyse aynıdır.

Tahmin değerleri. Model veri setindeki her ilan için bir tahmini fiyat üretmiştir. Gerçek fiyatı 33.791 TL olan 12 kişilik bir ilan için tahmin 14.381,03 TL'dir; tek değişkenli model lüks ve pahalı ilanların fiyatını düşük tahmin eder. Tablo 7′de iki örnek ilan için tahmini fiyatlar var.

Tablo 7. Basit doğrusal regresyon modeline göre tahmini fiyatlar

accommodates	Tahmini fiyat (TL)
2	3.887,92

accommodates	Tahmini fiyat (TL)
4	5.986,55

Örneğin 2 kişilik bir ilanın tahmini fiyatı 1.789,30 + 1.049,31 × 2 = 3.887,92 TL'dir. Bu tahminler gözlenen medyan fiyatlardan (2 kişi 3.100 TL, 4 kişi 5.016 TL) yüksektir, çünkü en küçük kareler yöntemi ortalamaya dayalı tahmin üretir ve sağa çarpık fiyat dağılımında ortalama pahalı ilanlardan etkilenir.

Bulguların yorumu. Kişi kapasitesi gecelik fiyatın istatistiksel olarak anlamlı ve pozitif bir belirleyicisidir. Ancak modelin açıklama gücü orta düzeydedir ve fiyattaki değişkenliğin büyük bölümü kapasite dışındaki etkenlere bağlıdır. Bu yüzden sonraki bölümde birden fazla değişken birlikte kullanılmıştır.

4.2. Çoklu doğrusal regresyon

4.2.1. Step 1: Başlangıç modeli

Başlangıç modelinde bağımlı değişken `price`'tır. Bağımsız değişkenler şunlardır:

- Sayısal (5): `accommodates`, `bedrooms`, `bathrooms`, `number_of_reviews`, `availability_365`.
- İki kategorili (2): `host_is_superhost` (referans: No) ve `shared_bath` (referans: No).
- Üç ve daha fazla kategorili (1): `room_type` (referans: Entire home/apt).

Kategorik değişkenler factor'e çevrilmiştir. R, referans dışındaki her kategori için 0/1 değerli bir kukla (dummy) değişken oluşturur ve kuklanın katsayısı o kategorinin referans kategoriye göre farkını gösterir.

$$price = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_{10} X_{10} + \varepsilon$$

Tablo 8. Başlangıç çoklu doğrusal regresyon modeli (Yönerge: Table 1 – Initial Multiple Linear Regression Model)

Terim	B	Std. hata	t	p	Sonuç
(Sabit)	254,31	110,67	2,298	0,022	anlamlı
accommodates	373,97	22,03	16,977	< 0,001	anlamlı
bedrooms	1.267,08	54,93	23,068	< 0,001	anlamlı
bathrooms	1.379,35	66,31	20,801	< 0,001	anlamlı
number_of_reviews	−4,26	0,46	−9,217	< 0,001	anlamlı
availability_365	1,36	0,27	4,972	< 0,001	anlamlı
host_is_superhost: Yes	1.054,27	59,66	17,672	< 0,001	anlamlı
shared_bath: Yes	−859,04	158,84	−5,408	< 0,001	anlamlı
room_type: Private room	−119,10	70,17	−1,697	0,090	anlamsız
room_type: Hotel room	4.455,75	233,26	19,102	< 0,001	anlamlı
room_type: Shared room	482,37	349,09	1,382	0,167	anlamsız
room_type (bütün olarak, kısmi F, df = 3)	F = 128,33			< 0,001	anlamlı

Terim	B	Std. hata	t	p	Sonuç
Model istatistikleri					
F (10; 16.292)	972,21			< 0,001	anlamlı
R^2	0,3737				
Düzeltilmiş R^2	0,3733				
Gözlem sayısı	16.303				

Genel anlamlılık. F(10; 16.292) = 972,21 ve p < 0,001 olduğundan en az bir bağımsız değişken fiyatı açıklamaktadır; başlangıç modeli istatistiksel olarak anlamlıdır.

Değişkenlerin anlamlılığı.

- Sayısal değişkenlerin ve iki kategorili değişkenlerin tamamı %5 düzeyinde anlamlıdır (Tablo 8).
- `room_type` değişkeninin kuklalarına tek tek bakıldığında, Hotel room kuklası anlamlıyken Private room (p = 0,090) ve Shared room (p = 0,167) kuklaları anlamlı değildir.
- Yönerge, üç ve daha fazla kategorili bir değişkenin anlamlılığının değişken bütün olarak ele alınarak değerlendirilmesini istemektedir. Bu nedenle `room_type`, `car` paketindeki `Anova()` fonksiyonuyla (Type II; Fox & Weisberg, 2019) kısmi F testine tabi tutulmuştur. Test, değişkenin üç kuklasını birlikte sınar.
- Test sonucu F(3; 16.292) = 128,33 ve p < 0,001′dir; `room_type` bütün olarak anlamlıdır.

Buna göre başlangıç modelindeki sekiz değişkenin tamamı anlamlıdır. Başlangıç modeli revizyon sonucunda değişmediği için sayısal ve kategorik katsayıların yorumu (Step 1, madde 8), tekrara düşmemek amacıyla Bölüm 4.2.3′te son model üzerinden bir arada yapılmıştır.

4.2.2. Step 2: Model revizyonu

Revizyon kuralı, p ≥ 0,05 olan değişkenlerin en yüksek p değerinden başlanarak birer birer çıkarılması ve modelin her seferinde yeniden tahmin edilmesidir. Kural uygulanmış, ancak başlangıç modelinde anlamsız değişken olmadığı için hiçbir değişken çıkarılmamıştır. Bütün değişkenlerin anlamlı çıkmasının bir nedeni örneklemin büyük olmasıdır (16.303 gözlem): büyük örneklemde standart hatalar küçülür ve küçük etkiler bile istatistiksel olarak anlamlı hâle gelir.

4.2.3. Step 3: Son model

Step 2′de hiçbir değişken çıkarılmadığından son model başlangıç modeliyle aynıdır. Yönerge istediği için son model ayrı bir tablo olarak Tablo 9′da verilmiştir; katsayılar Tablo 8 ile aynıdır.

Tablo 9. Son çoklu doğrusal regresyon modeli (Yönerge: Table 2 – Final Multiple Linear Regression Model)

Terim	B	Std. hata	t	p
(Sabit)	254,31	110,67	2,298	0,022
accommodates	373,97	22,03	16,977	< 0,001

Terim	B	Std. hata	t	p
bedrooms	1.267,08	54,93	23,068	< 0,001
bathrooms	1.379,35	66,31	20,801	< 0,001
number_of_reviews	−4,26	0,46	−9,217	< 0,001
availability_365	1,36	0,27	4,972	< 0,001
host_is_superhost: Yes	1.054,27	59,66	17,672	< 0,001
shared_bath: Yes	−859,04	158,84	−5,408	< 0,001
room_type: Private room	−119,10	70,17	−1,697	0,090
room_type: Hotel room	4.455,75	233,26	19,102	< 0,001
room_type: Shared room	482,37	349,09	1,382	0,167
room_type (bütün olarak, kısmi F, df = 3)	F = 128,33			< 0,001
F (10; 16.292)	972,21			< 0,001
R^2	0,3737			
Düzeltilmiş R^2	0,3733			

Not: `room_type` değişkeni bütün olarak anlamlıdır (car::Anova kısmi F testi: F(3; 16.292) = 128,33, p < 0,001). Private room ve Shared room kuklaları tek başlarına anlamlı değildir. Ancak çok kategorili bir değişken bütün olarak değerlendirildiğinden (Yönerge 2.2, Step 2), `room_type` bütün kategorileriyle birlikte modelde tutulmuştur.

Son modelin anlamlılığı ve denklemi. Son model istatistiksel olarak anlamlıdır (F(10; 16.292) = 972,21, p < 0,001). Kukla değişkenler ilgili kategori için 1, diğer durumlarda 0 değerini almak üzere tahmini denklem şöyledir:

$$\widehat{price} = 1267,08\,bedrooms + 1379,35\,bathrooms - 4,26\,reviews + 1,36\,availability + 1054,27\,Superhost - 859,04\,SharedBath - 119,10\,P$$

Denklemde `reviews` = `number_of_reviews`, `availability` = `availability_365` anlamındadır.

Sayısal katsayıların yorumu. Bütün yorumlar diğer değişkenler sabitken geçerlidir.

- `bedrooms` (B = 1.267,08): Bir ek yatak odası gecelik fiyatı ortalama 1.267 TL artırır.
- `bathrooms` (B = 1.379,35): Bir ek banyo fiyatı ortalama 1.379 TL artırır.
- `accommodates` (B = 373,97): Bir kişilik ek kapasite fiyatı ortalama 374 TL artırır. Bu etki basit regresyondaki 1.049,31 TL'den belirgin biçimde küçüktür. Kapasite genellikle yatak odası ve banyo sayısıyla birlikte arttığı için basit modelde bu değişkenlerin etkisi de `accommodates` katsayısına yükleniyordu. Çoklu modelde etkiler ayrıştırılmış ve katsayı kapasitenin kendi etkisini gösterir hâle gelmiştir.
- `number_of_reviews` (B = −4,26): Her ek yorum, fiyatın ortalama 4,26 TL daha düşük olmasıyla ilişkilidir.
- `availability_365` (B = 1,36): Yıl içinde bir gün daha müsait olmak fiyatı ortalama 1,36 TL artırır.

Kategorik katsayıların yorumu. Yorumlar referans kategoriye göre ve diğer değişkenler sabitken geçerlidir.

- `host_is_superhost` = Yes (B = 1.054,27): Superhost ev sahiplerinin ilanları Superhost olmayanlarınkinden ortalama 1.054 TL daha pahalıdır.
- `shared_bath` = Yes (B = −859,04): Paylaşımlı banyolu ilanlar özel banyolu ilanlardan ortalama 859 TL daha ucuzdur.
- `room_type` = Hotel room (B = 4.455,75): Otel odaları, aynı kapasite, yatak odası ve banyo sayısına sahip bütün ev/dairelerden ortalama 4.456 TL daha pahalıdır.
- `room_type` = Private room ve Shared room: Bu kuklalar tek başlarına anlamlı değildir; diğer değişkenler sabitken özel ve paylaşımlı odaların fiyatı bütün ev/dairelerden istatistiksel olarak farklı değildir. Oysa ham ortalamalar arasında büyük fark vardır: bütün ev/dairelerde ortalama fiyat 6.155,73 TL, özel odalarda 4.255,84 TL'dir. Bu farkın büyük kısmı, özel odaların daha az yatak odasına (ortalama 1,04; bütün ev/dairelerde 1,58), banyoya ve kapasiteye sahip olmasından gelir. Model bu farkı ilgili sayısal değişkenlerle zaten açıklamaktadır.

Özel kural (Special Rule). Son modelde hem sayısal hem kategorik bağımsız değişkenler olduğu için sayısal (ör. `bedrooms`) ve kategorik (ör. `host_is_superhost`) katsayılar doğrudan son modelden yorumlanmıştır. Başlangıç modelinden ayrıca katsayı yorumlamaya gerek kalmamıştır.

İstatistiksel anlamlılık ve pratik önem. Büyük örneklemde istatistiksel anlamlılık, etkinin pratikte önemli olduğu anlamına gelmez. Örneğin `availability_365` anlamlıdır ($p < 0,001$), ama bir günlük ek müsaitliğin fiyata katkısı yalnızca 1,36 TL'dir. Yatak odası, banyo ve Superhost statüsünün etkileri ise hem anlamlıdır hem de binlerce TL düzeyindedir.

R^2, düzeltilmiş R^2 ve başlangıç modeliyle karşılaştırma. Model karşılaştırması Tablo 10′da verilmiştir.

Tablo 10. Doğrusal regresyon modellerinin karşılaştırılması

Model	Bağımsız değişken sayısı	F	R^2	Düzeltilmiş R^2
Basit doğrusal regresyon (accommodates)	1	6.431,74	0,2829	0,2829
Çoklu regresyon – başlangıç modeli	8	972,21	0,3737	0,3733
Çoklu regresyon – son model	8	972,21	0,3737	0,3733

- Son model, fiyattaki değişkenliğin yaklaşık %37,4′ünü açıklamaktadır ($R^2 = 0,3737$).
- Düzeltilmiş R^2 (0,3733) R^2′ye çok yakındır; modele eklenen değişkenler açıklama gücüne gerçek bir katkı sağlamaktadır.
- Hiçbir değişken çıkarılmadığından son modelin açıklama gücü başlangıç modeliyle aynıdır.

- Basit regresyona göre R^2 0,2829′dan 0,3737′ye yükselmiş, artıkların standart hatası 3.668 TL'den 3.429 TL'ye düşmüştür.

5. İkili Lojistik Regresyon Sonuçları

Dört lojistik regresyon modelinin bağımlı değişkeni Bölüm 2.5′te oluşturulan `high_price` değişkenidir (1 = yüksek fiyat). Modeller `glm(..., family = binomial)` ile tahmin edilmiştir. Genel model şöyledir:

$$\text{logit}(p) = \ln\left[\frac{p}{1-p}\right] = \beta_0 + \beta_1 X_1 + ... + \beta_k X_k$$

Temel kavramlar. Yorumlarda şu kavramlar kullanılmıştır:

- p: İlanın yüksek fiyatlı olma olasılığı.
- Odds: p/(1 − p), yani olayın gerçekleşme olasılığının gerçekleşmeme olasılığına oranı.
- B katsayısı: X'teki bir birimlik artışın log-odds üzerindeki etkisi.
- Exp(B) (odds oranı): X bir birim arttığında odds'un kaç katına çıktığı. Exp(B) > 1 odds'un arttığını, Exp(B) < 1 azaldığını gösterir.

Exp(B), olasılığın değil odds'un çarpımsal değişimini ifade eder. Odds'un iki katına çıkması olasılığın da iki katına çıktığı anlamına gelmez. Örneğin bir ilan için olasılık 0,27′den 0,59′a yükselirken odds 0,37′den 1,44′e çıkmaktadır (Tablo 12).

Katsayıların anlamlılığı Wald z testiyle değerlendirilmiştir. Bütün modellerde sınıflandırma eşiği 0,50′dir.

Uyum iyiliği ölçütleri. Her model için Hosmer–Lemeshow (HL) testi `ResourceSelection` paketindeki `hoslem.test()` fonksiyonuyla (Lele et al., 2023), McFadden, Cox & Snell ve Nagelkerke pseudo R^2 değerleri `DescTools` paketindeki `PseudoR2()` fonksiyonuyla (Signorell, 2025) hesaplanmıştır.

Hosmer–Lemeshow testi ilanları tahmini olasılığa göre on gruba ayırır ve her gruptaki gözlenen ve beklenen yüksek fiyatlı ilan sayılarını karşılaştırır. H_0 "model veriye uymaktadır" olduğu için p > 0,05 iyi uyum, p < 0,05 kötü uyum anlamına gelir.

Pseudo R^2 değerleri doğrusal R^2 gibi yorumlanmaz. Lojistik regresyonda bağımlı değişken yalnızca 0 ve 1 değerlerini alır ve model en küçük kareler yerine en çok olabilirlik (maximum likelihood) yöntemiyle tahmin edilir. Bu yüzden doğrusal regresyondaki anlamıyla bir "açıklanan varyans oranı" yoktur. Pseudo R^2, modelin olabilirliğinin yalnızca sabit terim içeren modele göre ne kadar iyileştiğini ölçer ve "varyansın %X'i açıklandı" diye okunamaz. McFadden R^2 doğası gereği düşük değerler alır; 0,2–0,4 aralığı iyi uyum sayılır. Cox & Snell R^2 ikili bağımlı değişkende 1′e ulaşamaz ve bu veride alabileceği en yüksek değer 0,7500′dür. Nagelkerke R^2 ise Cox & Snell değerini bu en yüksek değere bölerek 0–1 aralığına ölçekler. Bu ölçütler en çok aynı veri üzerindeki modelleri karşılaştırmak için işe yarar.

Sınıflandırma başarısı. Bağımlı değişkenin dağılımı neredeyse eşittir: 8.162 ilan 0 (%50,06), 8.141 ilan 1 (%49,94) değerini almaktadır. Hiçbir değişken kullanmadan bütün ilanları çoğunluk sınıfı olan “0” olarak tahmin etmek bile %50,06 doğruluk verirdi. Accuracy değerleri bu yüzden %50,06′lık taban orana göre yorumlanmıştır.

5.1. Model 1: Sayısal bağımsız değişken (accommodates)

Model 1, yüksek fiyatlı olmayı yalnızca kişi kapasitesiyle açıklar. Katsayılar Tablo 11′dedir.

Tablo 11. Model 1 katsayıları (high_price ~ accommodates)

Terim	B	Std. hata	z	p	Exp(B)
(Sabit)	−2,3503	0,0470	−50,017	< 0,001	0,0953
accommodates	0,6782	0,0134	50,638	< 0,001	1,9704

Anlamlılık ve katsayılar. `accommodates` anlamlıdır (z = 50,64, p < 0,001). B = 0,6782 pozitif olduğu için kapasite arttıkça yüksek fiyatlı olma olasılığı da artar; teknik olarak bir kişilik kapasite artışı log-odds’u 0,6782 artırır. Exp(B) = 1,9704′tür: kapasite bir kişi arttığında ilanın yüksek fiyatlı olma odds’u 1,97 katına çıkar (%97,0 artış). Sabit terimden gelen $\text{Exp}(B_0)$ = 0,0953, kapasitenin 0 olduğu durumdaki odds’tur ve pratik bir anlamı yoktur.

Tahmini lojistik regresyon denklemi:

$$\text{logit}(p) = \ln\left[\frac{p}{1-p}\right] = -2,3503 + 0,6782 \times accommodates$$

$$p = \frac{1}{1 + e^{-(-2,3503 + 0,6782 \times accommodates)}}$$

Tablo 12. Model 1′e göre tahmini olasılıklar

accommodates	logit	Odds	Tahmini olasılık
2	−0,9939	0,3701	0,2701
4	0,3626	1,4370	0,5897
6	1,7190	5,5790	0,8480

Tahmini olasılıklar. 2 kişilik bir ilanın yüksek fiyatlı olma olasılığı 0,2701, 4 kişilik bir ilanın 0,5897, 6 kişilik bir ilanın 0,8480′dir. Veri setindeki bütün ilanlar için tahmini olasılıklar 0,1581 ile 0,9998 arasındadır.

Tablo 12 odds ile olasılık arasındaki farkı da gösterir. Odds her iki kişilik artışta aynı oranla çarpılarak büyür, olasılıktaki artış ise sabit değildir: 2′den 4 kişiye geçişte olasılık 0,2701′den 0,5897′ye, 4′ten 6 kişiye geçişte ise 0,5897′den 0,8480′e yükselmektedir.

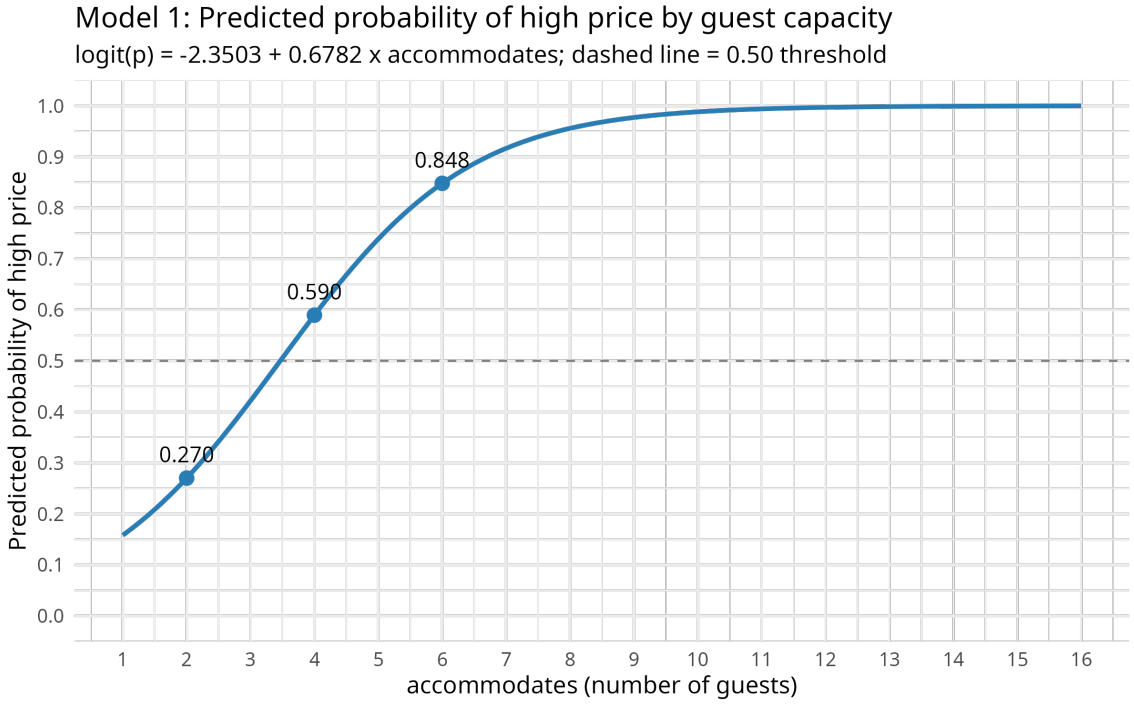
Uyum iyiliği. Hosmer–Lemeshow testinde χ^2 = 37,14, df = 4 ve p < 0,001′dir; H_0 reddedilir ve uyum yetersizdir. Test için on grup istenmiş, ancak yalnızca altı grup oluşabilmiştir. `accommodates` yalnızca 16 farklı değer alır ve ilanların %35,23′ü (5.743 ilan) 2 kişiliktir. Aynı tahmini olasılığa sahip çok sayıda ilan olduğu için grup sınırları çakışmış ve serbestlik derecesi

6 − 2 = 4 olmuştur. Pseudo R^2 değerleri McFadden 0,1803, Cox & Snell 0,2211 ve Nagelkerke 0,2948′dir. Tek değişkenli bir model için McFadden değeri iyi uyum sınırına (0,2) yakındır.

Tablo 13. Model 1 karışıklık matrisi (eşik = 0,50)

	Tahmin: 0	Tahmin: 1
Gerçek: 0	TN = 6.361	FP = 1.801
Gerçek: 1	FN = 2.866	TP = 5.275

Sınıflandırma başarısı. Tablo 13′teki karışıklık matrisine göre accuracy = (5.275 + 6.361) / 16.303 = 0,7137 (%71,37). Bu, %50,06′lık taban orana göre 21,31 puanlık bir iyileşmedir. Yanlış negatifler (2.866) yanlış pozitiflerden (1.801) fazladır; model küçük kapasiteli ama yüksek fiyatlı ilanları kaçırmaya daha yatkındır.



Şekil 1. Model 1: Kişi kapasitesine göre yüksek fiyatlı olma olasılığı (lojistik eğri). Kesikli çizgi 0,50 eşiğidir.

Grafiğin yorumu. Şekil 1′de kapasite arttıkça yüksek fiyatlı olma olasılığı S biçiminde artar. Olasılık 1 kişilik ilanlarda yaklaşık 0,16′dır ve 3 ile 4 kişi arasında 0,50 eşiğini geçer. Bu yüzden 0,50 eşiğinde 4 ve üzeri kişilik ilanlar “yüksek fiyatlı” olarak sınıflandırılır. Eğri orta kapasitelerde dik, uçlarda yatıktır. En büyük olasılık artışı 2–6 kişi aralığındadır; 8 kişinin üzerinde olasılık 1′e yaklaştığı için ek kapasite olasılığı çok az değiştirir.

5.2. Model 2: İki kategorili bağımsız değişken (host_is_superhost)

Referans kategori No’dur (Superhost olmayan ev sahibi). Katsayılar Tablo 14′tedir.

Tablo 14. Model 2 katsayıları (high_price ~ host_is_superhost)

Terim	B	Std. hata	z	p	Exp(B)
(Sabit)	−0,3089	0,0195	−15,881	< 0,001	0,7343
host_is_superhost: Yes	0,9260	0,0344	26,950	< 0,001	2,5244

Anlamlılık ve katsayılar. Superhost statüsü anlamlıdır (z = 26,95, p < 0,001). B = 0,9260 pozitif olduğu için Superhost ilanlarının yüksek fiyatlı olma olasılığı daha yüksektir. Exp(B) = 2,5244′tür: Superhost ev sahiplerinin ilanlarının yüksek fiyatlı olma odds'u, Superhost olmayanların ilanlarının odds'unun 2,52 katıdır. Sabit terimden gelen $\text{Exp}(B_0) = 0{,}7343$ ise referans grubun (Superhost olmayan) odds'udur.

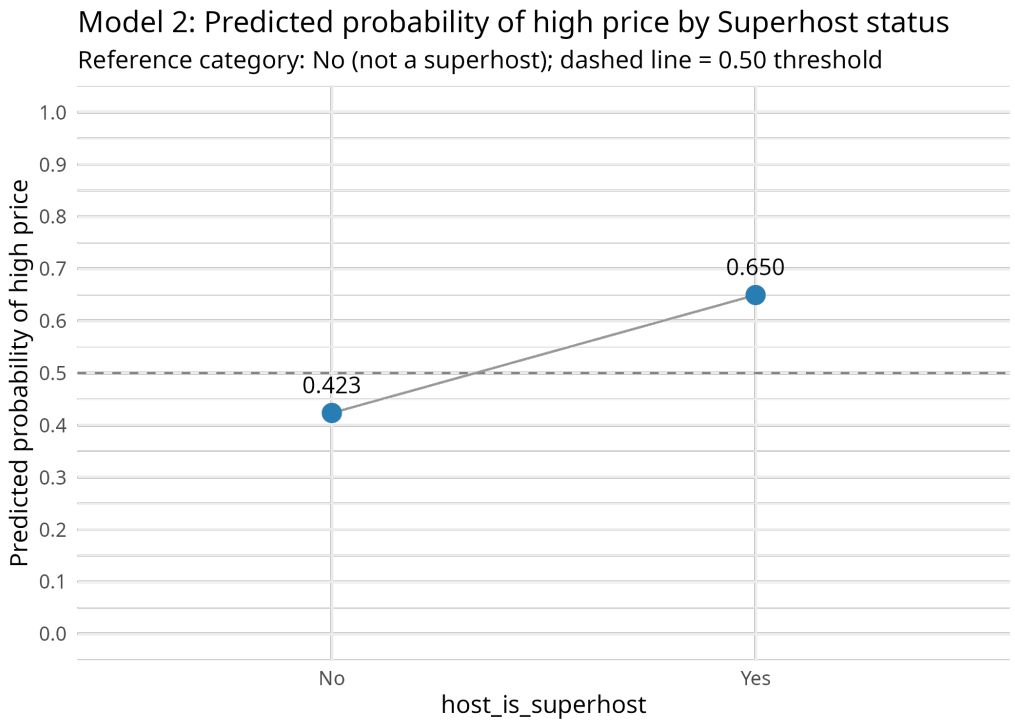
Superhost olmayan ilanlarda tahmini olasılık 0,4234 ve odds 0,7343, Superhost ilanlarında olasılık 0,6496 ve odds 1,8536′dır. Odds'ların oranı Exp(B) değerini verir, olasılıkların oranı ise 2,52 değildir. Bu yüzden sonuç "olasılık 2,52 kat artar" diye yorumlanamaz.

Uyum iyiliği. Hosmer–Lemeshow testi bu modelde uygulanamamıştır. Modelde tek bir iki kategorili değişken olduğu için aynı kategorideki bütün ilanlara aynı olasılık atanır. Yalnızca iki farklı tahmini olasılık olduğundan test için gereken on grup oluşturulamaz. Daha temel bir neden de modelin "doymuş" (saturated) olmasıdır: her kategori için tahmin edilen olasılık, o kategorideki gerçek yüksek fiyat oranına tam olarak eşittir. Gözlenen ve beklenen değerler tanım gereği eşit olduğundan test hesaplansa bile uyum hakkında bilgi vermez. Modelin uyumu bu nedenle pseudo R^2 değerleriyle değerlendirilmiştir: McFadden 0,0333, Cox & Snell 0,0451, Nagelkerke 0,0602. Değerler çok düşüktür; Superhost statüsü anlamlı olsa da yüksek fiyatı tek başına açıklamakta zayıf kalır.

Tablo 15. Model 2 karışıklık matrisi (eşik = 0,50)

	Tahmin: 0	Tahmin: 1
Gerçek: 0	TN = 6.243	FP = 1.919
Gerçek: 1	FN = 4.584	TP = 3.557

Sınıflandırma başarısı. Tablo 15′teki karışıklık matrisine göre accuracy = (3.557 + 6.243) / 16.303 = 0,6011 (%60,11) ve taban orana göre iyileşme 10,05 puandır. Model Superhost olan bütün ilanları "yüksek" (p = 0,6496), olmayanları "düşük" (p = 0,4234) olarak sınıflandırır. Yüksek fiyatlı ilanların önemli bir kısmının ev sahibi Superhost olmadığı için yanlış negatif sayısı yüksektir (4.584).



Şekil 2. Model 2: Superhost statüsüne göre yüksek fiyatlı olma olasılığı. Referans kategori: No.

Grafiğin yorumu. Modelde sayısal bağımsız değişken olmadığı için sürekli bir lojistik eğri çizilemez. Yönerge 4.3, kategorik değişkenlerde referans kategoriden diğer kategorilere geçince olasılığın nasıl değiştiğinin yorumlanmasını öngörür; bu yüzden Şekil 2′de her kategori için tahmini olasılık gösterilmiştir. Referans kategoriden (No: 0,4234) Superhost kategorisine (Yes: 0,6496) geçince yüksek fiyatlı olma olasılığı 0,50 eşiğinin altından üstüne çıkar.

5.3. Model 3: Çok kategorili bağımsız değişken (room_type)

`room_type` dört düzeyli bir factor'e çevrilmiş ve referans kategori Entire home/apt seçilmiştir. Katsayılar Tablo 16′dadır.

Tablo 16. Model 3 katsayıları (high_price ~ room_type)

Terim	B	Std. hata	z	p	Exp(B)
(Sabit)	0,3184	0,0187	17,058	< 0,001	1,3749
room_type: Private room	−1,2749	0,0393	−32,450	< 0,001	0,2794
room_type: Hotel room	0,2018	0,1382	1,460	0,144	1,2236
room_type: Shared room	−1,8717	0,2354	−7,951	< 0,001	0,1539

Anlamlılık. `room_type`, olabilirlik oranı ki-kare testiyle (`car::Anova`; Fox & Weisberg, 2019) bütün olarak sınanmıştır. $\chi^2(3) = 1.222{,}9$ ve $p < 0{,}001$ olduğundan `room_type` bütün olarak anlamlıdır.

Kategorilerin referans kategoriye göre odds farkları.

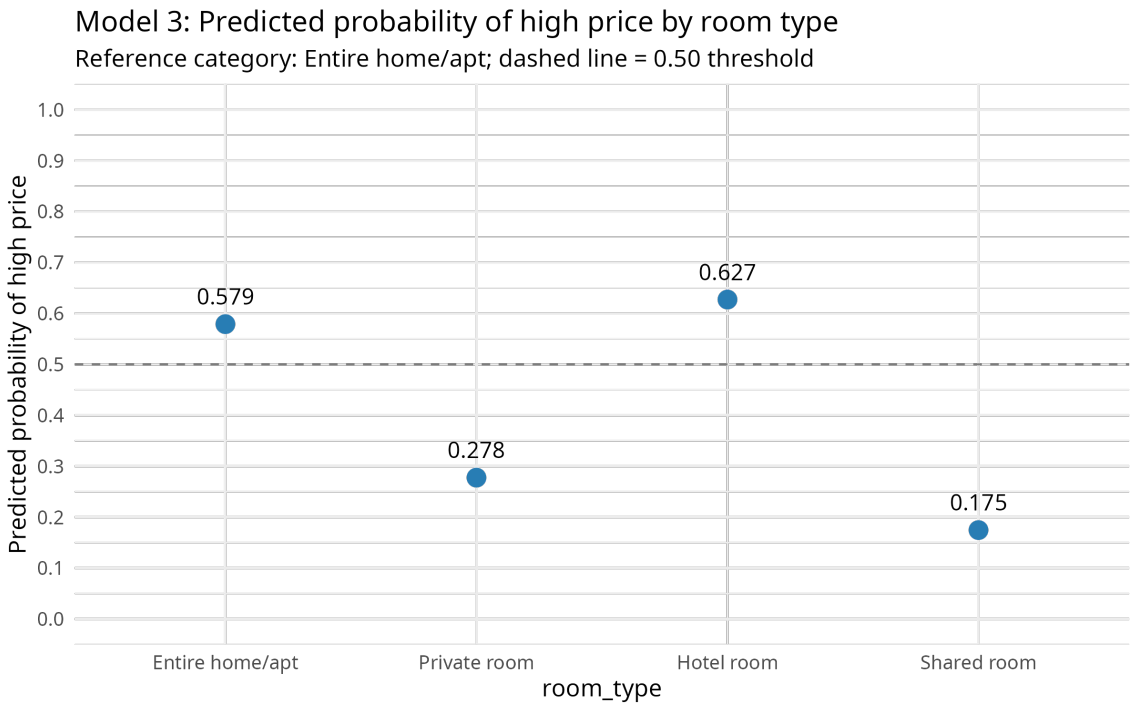
- Private room (Exp(B) = 0,2794, $p < 0{,}001$): Özel odaların yüksek fiyatlı olma odds'u bütün ev/dairelerin 0,28 katıdır, yani %72,1 daha düşüktür.
- Hotel room (Exp(B) = 1,2236, $p = 0{,}144$): Otel odalarının odds'u bütün ev/dairelerden %22,4 yüksektir, ancak bu fark istatistiksel olarak anlamlı değildir. Kategoride yalnızca 228 ilan olması standart hatayı büyütür.
- Shared room (Exp(B) = 0,1539, $p < 0{,}001$): Paylaşımlı odaların odds'u bütün ev/dairelerin 0,15 katıdır, yani %84,6 daha düşüktür.
- Sabit terim: $\text{Exp}(B_0) = 1{,}3749$, referans kategorinin (Entire home/apt) odds'udur.

Uyum iyiliği. Hosmer–Lemeshow testi Model 2′deki nedenlerle bu modelde de uygulanamamıştır. Modelde yalnızca dört farklı tahmini olasılık vardır, bu yüzden on grup oluşturulamaz. Model doymuştur; her kategorinin tahmini olasılığı o kategorideki gerçek oranla aynıdır. Test zorla hesaplansaydı gözlenen ve beklenen değerler eşit çıkacağı için "mükemmel uyum" gibi görünen ama bilgi taşımayan bir sonuç verirdi. Bu nedenle test sonucu üretilmemiştir. Pseudo R^2 değerleri McFadden 0,0541, Cox & Snell 0,0723 ve Nagelkerke 0,0964′tür; oda tipi anlamlı olsa da tek başına açıklama gücü düşüktür.

Tablo 17. Model 3 karışıklık matrisi (eşik = 0,50)

	Tahmin: 0	Tahmin: 1
Gerçek: 0	TN = 3.118	FP = 5.044
Gerçek: 1	FN = 1.180	TP = 6.961

Sınıflandırma başarısı. Tablo 17′deki karışıklık matrisine göre accuracy = (6.961 + 3.118) / 16.303 = 0,6182 (%61,82) ve taban orana göre iyileşme 11,76 puandır. Model, tahmini olasılığı 0,50′nin üzerinde olan Entire home/apt ve Hotel room ilanlarının tamamını "yüksek", Private room ve Shared room ilanlarının tamamını "düşük" olarak sınıflandırır. Ucuz bütün ev/daireler de "yüksek" sınıfına girdiği için yanlış pozitif sayısı yüksektir (5.044).



Şekil 3. Model 3: Oda tipine göre yüksek fiyatlı olma olasılığı. Referans kategori: Entire home/apt.

Grafiğin yorumu. Model 2′de olduğu gibi sayısal bağımsız değişken olmadığından Şekil 3′te kategori bazında tahmini olasılıklar gösterilmiştir; bu gösterim yönerge 4.3′ün kategoriler arası değişime ilişkin yorum ifadesine uygundur. Referans kategoride (Entire home/apt) olasılık 0,5789′dur. Hotel room'da olasılık hafifçe yükselir (0,6272), Private room'da (0,2776) ve Shared room'da (0,1746) ise belirgin biçimde düşer.

5.4. Model 4: Karma bağımsız değişkenli çoklu lojistik regresyon

Bu modelde çoklu doğrusal regresyondaki bütün değişkenler kullanılmıştır:

- Sayısal: `accommodates`, `bedrooms`, `bathrooms`, `number_of_reviews`, `availability_365`.
- Kategorik: `host_is_superhost` (referans: No), `shared_bath` (referans: No), `room_type` (referans: Entire home/apt).

Katsayılar, Exp(B) değerleri ve odds'taki yüzde değişimler Tablo 18′dedir.

Tablo 18. Model 4 katsayıları (karma model)

Terim	B	Std. hata	z	p	Exp(B)	Odds değişimi
(Sabit)	−3,1880	0,1071	−29,761	< 0,001	0,0413	
accommodates	0,3791	0,0187	20,233	< 0,001	1,4609	+%46,09
bedrooms	0,7159	0,0462	15,500	< 0,001	2,0461	+%104,61
bathrooms	0,6209	0,0815	7,618	< 0,001	1,8607	+%86,07
number_of_reviews	−0,0034	0,0003	−9,828	< 0,001	0,9966	−%0,34
availability_365	0,0005	0,0002	2,785	0,005	1,0005	+%0,05

Terim	B	Std. hata	z	p	Exp(B)	Odds değişimi
host_is_superhost: Yes	0,9203	0,0411	22,407	< 0,001	2,5100	+ %151,00
shared_bath: Yes	−0,3349	0,1193	−2,806	0,005	0,7154	−%28,46
room_type: Private room	−0,3713	0,0474	−7,838	< 0,001	0,6898	−%31,02
room_type: Hotel room	1,4046	0,1459	9,624	< 0,001	4,0738	+ %307,38
room_type: Shared room	−0,3366	0,2853	−1,180	0,238	0,7142	−%28,58

Anlamlılık. Bütün değişkenler %5 düzeyinde anlamlıdır. Tek dereceli değişkenler Wald z testiyle, `room_type` ise bütün olarak olabilirlik oranı testiyle sınanmıştır ($\chi^2(3) = 187{,}03$, $p < 0{,}001$). Shared room kuklası tek başına anlamlı değildir ($p = 0{,}238$), ancak değişken bütün olarak değerlendirildiği için modelde tutulmuştur.

Sayısal katsayıların yorumu. Bütün yorumlar diğer değişkenler sabitken ve bir birimlik artış için geçerlidir.

- `bedrooms` (Exp(B) = 2,0461): Bir ek yatak odası yüksek fiyatlı olma odds'unu 2,05 katına çıkarır. Modeldeki en güçlü sayısal etki budur.
- `bathrooms` (Exp(B) = 1,8607): Bir ek banyo odds'u 1,86 katına çıkarır.
- `accommodates` (Exp(B) = 1,4609): Bir kişilik ek kapasite odds'u %46,09 artırır. Etki Model 1′deki 1,9704′ten küçüktür, çünkü burada yatak odası ve banyo sayısı sabit tutulduğunda kapasitenin kendi etkisi ölçülmektedir.
- `number_of_reviews` (Exp(B) = 0,9966): Tek bir yorum çok küçük bir birim olduğu için 100 yorum üzerinden okumak daha anlaşılırdır: 100 ek yorum yüksek fiyatlı olma odds'unu 0,7104 katına indirir (%28,96 azalış).
- `availability_365` (Exp(B) = 1,0005): 100 gün daha fazla müsait olmak odds'u 1,0541 katına çıkarır (%5,41 artış). Etki istatistiksel olarak anlamlı ama pratikte küçüktür; büyük örneklemde küçük etkiler de anlamlı çıkabilir.

Kategorik katsayıların yorumu. Yorumlar diğer değişkenler sabitken ve referans kategoriye göre geçerlidir.

- `host_is_superhost` = Yes (Exp(B) = 2,5100): Superhost ilanlarının yüksek fiyatlı olma odds'u Superhost olmayanların 2,51 katıdır. Bu değer Model 2′dekine (2,5244) çok yakındır, yani Superhost etkisi diğer özelliklerden büyük ölçüde bağımsızdır.
- `shared_bath` = Yes (Exp(B) = 0,7154): Paylaşımlı banyolu ilanların odds'u özel banyolu ilanlardan %28,46 düşüktür.
- `room_type` = Hotel room (Exp(B) = 4,0738): Aynı kapasite, yatak odası ve banyo sayısında otel odalarının odds'u bütün ev/dairelerin 4,07 katıdır. Model 3′te anlamlı olmayan bu fark

Model 4′te en güçlü etki olmuştur. Otel odalarında ortalama yatak odası sayısı daha düşük (0,97; bütün ev/dairelerde 1,58), ortalama fiyat ise daha yüksektir (8.504,00 TL ve 6.155,73 TL). Diğer özellikler sabit tutulunca otel odası olmanın kendi etkisi ortaya çıkar.

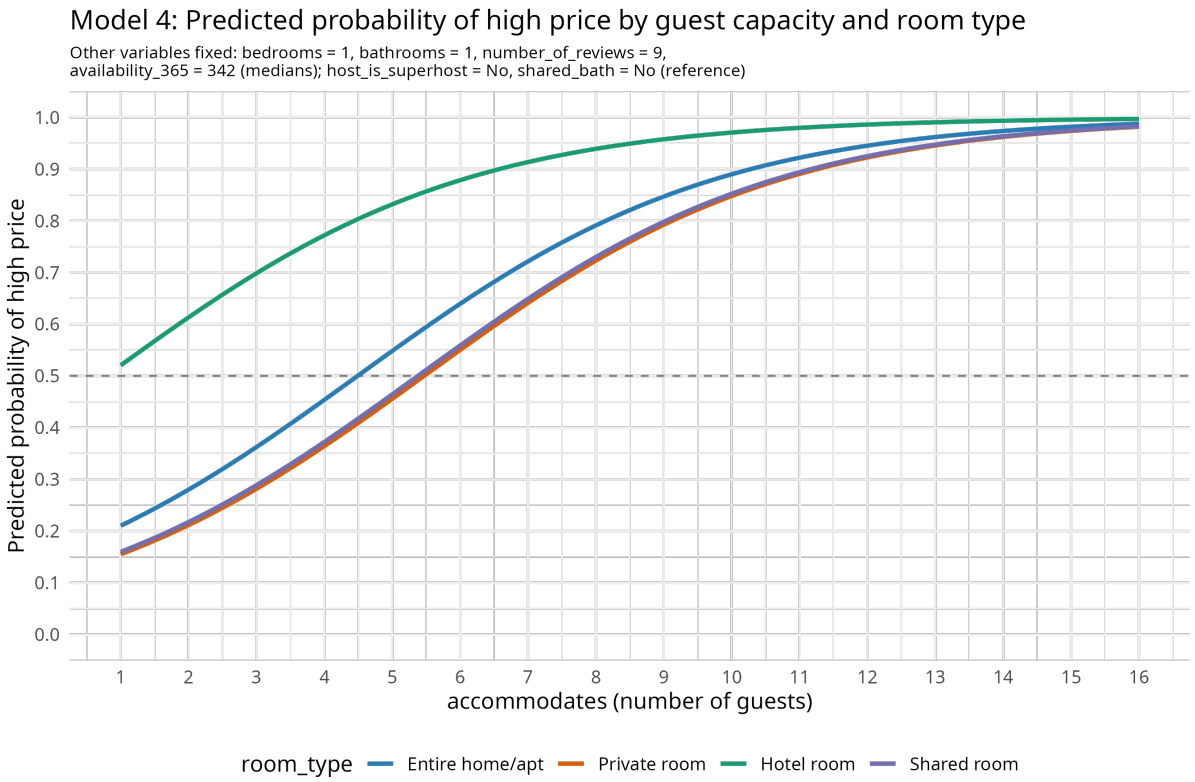
- `room_type` = Private room (Exp(B) = 0,6898): Özel odaların odds'u %31,02 daha düşüktür. Fark Model 3′teki %72,1′den çok daha küçüktür, çünkü özel odaların daha az yatak odası, banyo ve kapasiteye sahip olmasından gelen kısım diğer değişkenlerle açıklanmıştır.
- `room_type` = Shared room (Exp(B) = 0,7142, p = 0,238): Bu kukla anlamlı değildir; diğer özellikler sabitken paylaşımlı odalar bütün ev/dairelerden istatistiksel olarak farklı değildir.

Uyum iyiliği. Hosmer–Lemeshow testinde on grubun tamamı oluşmuştur. $\chi^2 = 65{,}00$, df = 8 ve $p < 0{,}001$ olduğundan H_0 reddedilir; teste göre modelin uyumu yeterli değildir. Ancak HL testi çok büyük örneklemlerde aşırı duyarlıdır ve 16.303 gözlemde gözlenen ve beklenen değerler arasındaki küçük farklar bile anlamlı çıkabilir. Bu yüzden uyum, pseudo R^2 ve sınıflandırma başarısıyla birlikte değerlendirilmiştir. Pseudo R^2 değerleri McFadden 0,2344, Cox & Snell 0,2774 ve Nagelkerke 0,3699′dur. McFadden değeri 0,2–0,4 aralığındadır ve dört modelin en yüksek değeridir.

Tablo 19. Model 4 karışıklık matrisi (eşik = 0,50)

	Tahmin: 0	Tahmin: 1
Gerçek: 0	TN = 6.660	FP = 1.502
Gerçek: 1	FN = 2.599	TP = 5.542

Sınıflandırma başarısı. Tablo 19′daki karışıklık matrisine göre accuracy = (5.542 + 6.660) / 16.303 = 0,7485 (%74,85). Bu, %50,06′lık taban orana göre 24,78 puanlık bir iyileşmedir ve dört model arasındaki en yüksek değerdir.



Şekil 4. Model 4: Kişi kapasitesine ve oda tipine göre yüksek fiyatlı olma olasılığı. Diğer değişkenler sabit tutulmuştur: bedrooms = 1, bathrooms = 1, number_of_reviews = 9, availability_365 = 342 (medyanlar); host_is_superhost = No, shared_bath = No (referans kategoriler).

Grafiğin yorumu. Şekil 4′te diğer sayısal değişkenler medyanlarında, diğer kategorik değişkenler ise referans kategorilerinde sabit tutulmuştur. Dört eğride de olasılık kapasiteyle birlikte artar; oda tipi eğriyi yukarı ya da aşağı kaydırır. 2 kişilik ilanlarda tahmini olasılık Entire home/apt için 0,280, Private room için 0,212, Hotel room için 0,613 ve Shared room için 0,218′dir. 6 kişilik ilanlarda aynı sırayla 0,639, 0,550, 0,878 ve 0,559′dur.

Hotel room eğrisi en üsttedir ve 1 kişilik kapasitede bile 0,50 eşiğinin üzerindedir. Private room ve Shared room katsayıları birbirine çok yakın olduğu için (−0,3713 ve −0,3366) bu iki eğri neredeyse üst üste biner; diğer özellikler sabitken bu iki oda tipi arasında pratikte fark yoktur. Kategoriler arasındaki fark orta kapasitelerde en büyüktür, çok yüksek kapasitelerde bütün eğriler 1′e yaklaşır. Bazı oda tiplerinde çok yüksek kapasiteli ilan neredeyse olmadığı için eğrilerin uç kısımları dikkatli yorumlanmalıdır.

5.5. Lojistik modellerin karşılaştırılması

Tablo 20. Lojistik regresyon modellerinin uyum iyiliği ve sınıflandırma başarısı

Model	HL χ^2 (df)	HL p	McFadden	Cox & Snell	Nagelkerke	Accuracy
Model 1: accommodates	37,14 (4)	< 0,001	0,1803	0,2211	0,2948	%71,37
Model 2: host_is_ superhost	uygulanamaz	–	0,0333	0,0451	0,0602	%60,11
Model 3: room_ type	uygulanamaz	–	0,0541	0,0723	0,0964	%61,82
Model 4: karma	65,00 (8)	< 0,001	0,2344	0,2774	0,3699	%74,85

Not: Karışıklık matrisleri Tablo 13, 15, 17 ve 19'da verilmiştir. Taban oran (bütün ilanları çoğunluk sınıfı "0" olarak tahmin etme) %50,06'dır. Model 1'de HL testi için on grup yerine altı grup oluşabilmiştir. Model 2 ve 3'te test, yalnızca 2 ve 4 farklı tahmini olasılık bulunduğundan ve modeller doymuş olduğundan uygulanamamıştır.

Dört modelin uyum ve sınıflandırma ölçütleri Tablo 20′dedir. Bütün ölçütlere göre en iyi model Model 4′tür, onu Model 1 izler. Model 1′den Model 4′e geçince bütün pseudo R^2 değerleri ve accuracy artmıştır. Yine de accuracy'nin yalnızca %71,37′den %74,85′e çıkması, sınıflandırmanın büyük bölümünün tek başına kapasite değişkeniyle yapılabildiğini gösterir. Tek kategorik değişkenli Model 2 ve 3 her kategoriye tek bir tahmin atadıkları için kaba bir sınıflandırma yapar, ama ikisi de taban oranın üzerindedir.

6. Sonuç

Doğrusal regresyon bulguları. Basit doğrusal regresyonda kişi kapasitesi gecelik fiyatın anlamlı ve pozitif bir belirleyicisi çıkmıştır: her ek kişi fiyatı ortalama 1.049,31 TL artırır. Ancak bu model fiyattaki değişkenliğin yalnızca %28,3′ünü açıklar (R^2 = 0,2829). Sayısal ve kategorik değişkenlerin birlikte kullanıldığı çoklu modelde başlangıçtaki sekiz değişkenin hepsi anlamlı çıkmış, bu yüzden revizyonda hiçbir değişken çıkarılmamıştır; `room_type` bütün olarak anlamlıdır. Son model fiyattaki değişkenliğin %37,4′ünü açıklar (R^2 = 0,3737, düzeltilmiş R^2 = 0,3733). Diğer değişkenler sabitken fiyatı en çok artıran özellikler otel odası olmak (+4.455,75 TL), banyo sayısı (+1.379,35 TL), yatak odası sayısı (+1.267,08 TL) ve Superhost statüsüdür (+1.054,27 TL). Paylaşımlı banyo (−859,04 TL) ve yorum sayısı ise fiyatla negatif yönde ilişkilidir.

Lojistik regresyon bulguları. Dört modelde de bağımsız değişkenler, bir ilanın medyan fiyatın (4.457,5 TL) üzerinde olma odds'uyla anlamlı biçimde ilişkilidir. Karma model (Model 4) en iyi uyumu (McFadden 0,2344, Nagelkerke 0,3699) ve en yüksek sınıflandırma başarısını (%74,85) vermiştir; bu, yaklaşık %50′lik taban orana göre belirgin bir iyileşmedir. Diğer değişkenler sabitken yüksek fiyatlı olma odds'unu en çok artıran özellikler otel odası olmak (4,07 kat), Superhost statüsü (2,51 kat), yatak odası (2,05 kat) ve banyo sayısıdır (1,86 kat). Hosmer–

Lemeshow testi Model 1 ve Model 4′te uyumun yetersiz olduğuna işaret etmiştir, ancak bu sonuç büyük örneklemden etkilenmiş olabilir. Model 2 ve Model 3′te test, modellerin yapısı nedeniyle uygulanamamıştır.

İstatistiksel olarak anlamlı değişkenler. Her iki analiz türünde de `accommodates`, `bedrooms`, `bathrooms`, `number_of_reviews`, `availability_365`, `host_is_superhost`, `shared_bath` ve bütün olarak `room_type` anlamlı bulunmuştur. Ancak `availability_365` örneğindeki gibi, büyük örneklemde bazı etkiler istatistiksel olarak anlamlı olsa da pratikte küçüktür.

Genel değerlendirme. Doğrusal ve lojistik modellerde katsayıların yönleri aynıdır. İstanbul'daki kısa dönem Airbnb ilanlarında fiyatı belirleyen başlıca etkenler mekânın büyüklüğü (kapasite, yatak odası ve banyo sayısı), kiralanan alanın türü ve ev sahibinin Superhost statüsüdür. Doğrusal model bu etkileri TL cinsinden, lojistik model ise yüksek fiyat grubunda olma odds'unun kaç kat değiştiği üzerinden ifade eder. İki modelde de fiyattaki değişkenliğin önemli bir kısmı açıklanamamıştır. Bu, fiyatın konum ve mekânın niteliği gibi bu çalışmada yer almayan etkenlere de bağlı olduğunu gösterir.

Kaynakça

Fox, J., & Weisberg, S. (2019). *An R companion to applied regression* (3rd ed.). Sage. https://socialsciences.mcmaster.ca/jfox/Books/Companion/

Inside Airbnb. (2026, 25 Eylül). *Istanbul, Marmara, Turkey: Detailed listings data (listings.csv.gz)* [Veri seti]. https://insideairbnb.com/get-the-data/

Lele, S. R., Keim, J. L., & Solymos, P. (2023). *ResourceSelection: Resource selection (probability) functions for use-availability data* (R paketi sürüm 0.3-6) [Bilgisayar yazılımı]. https://CRAN.R-project.org/package=ResourceSelection

R Core Team. (2024). *R: A language and environment for statistical computing* [Bilgisayar yazılımı]. R Foundation for Statistical Computing. https://www.R-project.org/

Signorell, A. (2025). *DescTools: Tools for descriptive statistics* (R paketi sürüm 0.99.60) [Bilgisayar yazılımı]. https://CRAN.R-project.org/package=DescTools

Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., … Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software, 4*(43), 1686. https://doi.org/10.21105/joss.01686

7. Ek – R Kodları

Analizler R 4.3.3 sürümüyle (R Core Team, 2024) RStudio'da yapılmıştır. Kullanılan paketler ve sürümleri şunlardır:

- `tidyverse` 2.0.0 (Wickham et al., 2019): veri okuma, düzenleme ve grafikler.
- `car` 3.1.2 (Fox & Weisberg, 2019): `Anova()` fonksiyonu.
- `ResourceSelection` 0.3.6 (Lele et al., 2023): `hoslem.test()` fonksiyonu.
- `DescTools` 0.99.60 (Signorell, 2025): `PseudoR2()` fonksiyonu.

Aşağıdaki kod, projede kullanılan altı R script'inin çalıştırılma sırasıyla birleştirilmiş hâlidir. Her bölümün başında ilgili yönerge maddeleri belirtilmiştir.

```
# ##############################################################################
# APPENDIX - R CODES
# Data Mining Midterm Project - Istanbul Airbnb Listings (Inside Airbnb)
# Data: listings.csv.gz, data release 25 Sep 2026 (data collected 28-29 Sep 2026)
#
# All R code used in the project, in the order it was run:
#   Section 1  01_import_explore.R      -> Guideline 1.2, 1.3
#   Section 2  02_cleaning.R            -> Guideline 1.4, 1.5, 1.6 (+ 1.1 tables)
#   Section 3  03_simple_linear.R       -> Guideline 2.1
#   Section 4  04_multiple_linear.R     -> Guideline 2.2 (Step 1-3, Special Rule)
#   Section 5  05_logistic_models.R     -> Guideline 3.1, 3.2, 3.3, 3.4
#   Section 6  06_logistic_evaluation.R -> Guideline 4.1, 4.2, 4.3
#
# Working directory must be the project folder (paths such as
# "data/listings.csv.gz" are relative to it).
# Packages: tidyverse, car, ResourceSelection, DescTools
# ##############################################################################




# ##############################################################################
# SECTION 1 - 01_import_explore.R
# Guideline: 1.2 Importing the Dataset, 1.3 Initial Dataset Examination
# Covers: data import (read_csv), head/dim/str/summary, detection of data problems
# ##############################################################################

library(tidyverse)

options(width = 120, tibble.width = Inf)

# ------------------------------------------------------------------------------
# 1.2 IMPORTING THE DATASET
# ------------------------------------------------------------------------------

file_path <- "data/listings.csv.gz"

listings <- read_csv(file_path, guess_max = 30000, show_col_types = FALSE)

cat("Parsing problems while reading:", nrow(problems(listings)), "\n")

cat("\n===== 1.2 IMPORT REPORT =====\n")
cat("Original file format : CSV compressed with gzip (.csv.gz)\n")
cat("R function used      : readr::read_csv()\n")
cat("Number of observations (rows)   :", nrow(listings), "\n")
cat("Number of variables (columns)   :", ncol(listings), "\n")

# ------------------------------------------------------------------------------
# 1.3 INITIAL DATASET EXAMINATION - the four required functions
# ------------------------------------------------------------------------------
```

```r
cat("\n===== head() : first 6 rows =====\n")
print(head(listings))

cat("\n===== dim() : rows and columns =====\n")
print(dim(listings))

cat("\n===== str() : type of every variable =====\n")
str(listings, give.attr = FALSE)

cat("\n===== summary() : summary statistics of every variable =====\n")
print(summary(listings))

# ------------------------------------------------------------------------
# 1.3 PROBLEM DETECTION
# ------------------------------------------------------------------------

col_types <- sapply(listings, function(x) class(x)[1])
cat("\n===== A) Column types =====\n")
print(table(col_types))

cat("\nClass of price:", class(listings$price), "\n")
cat("Example price values:\n")
print(head(na.omit(listings$price), 5))

empty_cols <- names(listings)[colSums(is.na(listings)) == nrow(listings)]
cat("\nCompletely empty columns (", length(empty_cols), "):\n", sep = "")
print(empty_cols)

cat("\nClass of bathrooms_text:", class(listings$bathrooms_text), "\n")
print(head(unique(listings$bathrooms_text), 8))

cat("\nClass of host_is_superhost     :", class(listings$host_is_superhost), "\n")
cat("Class of host_identity_verified:", class(listings$host_identity_verified),
"\n")

na_table <- tibble(
  variable  = names(listings),
  n_missing = colSums(is.na(listings)),
  pct       = round(100 * n_missing / nrow(listings), 1)
) %>%
  filter(n_missing > 0) %>%
  arrange(desc(n_missing))

cat("\n===== B) Variables with missing values =====\n")
print(na_table, n = Inf)

cat("\nreview_scores_rating missing           :",
sum(is.na(listings$review_scores_rating)), "\n")
cat("listings with number_of_reviews == 0   :", sum(listings$number_of_reviews ==
0), "\n")
cat("missing rating AND reviews == 0 (both) :",
    sum(is.na(listings$review_scores_rating) & listings$number_of_reviews == 0),
"\n")

cat("\n===== C) Categorical variables =====\n")

cat("\nroom_type:\n")
print(table(listings$room_type, useNA = "ifany"))

cat("\nhost_is_superhost:\n")
print(table(listings$host_is_superhost, useNA = "ifany"))

cat("\nneighbourhood_cleansed - number of districts:",
    n_distinct(listings$neighbourhood_cleansed), "\n")
cat("Values with extra spaces:",
    sum(listings$neighbourhood_cleansed !=
str_squish(listings$neighbourhood_cleansed)), "\n")
print(sort(table(listings$neighbourhood_cleansed), decreasing = TRUE))
```

```r
cat("\nbathrooms_text - number of different values:",
    n_distinct(listings$bathrooms_text), "\n")
bath_no_number <- listings %>%
  filter(!is.na(bathrooms_text), !str_detect(bathrooms_text, "[0-9]")) %>%
  count(bathrooms_text)
cat("bathrooms_text values without a number:\n")
print(bath_no_number)

pt_counts <- count(listings, property_type, sort = TRUE)
cat("\nproperty_type - number of levels:", nrow(pt_counts),
    "| levels with fewer than 30 listings:", sum(pt_counts$n < 30), "\n")

cat("\nlicense - number of different values:", n_distinct(listings$license), "\n")
print(head(count(listings, license, sort = TRUE), 8))

price_num <- parse_number(listings$price)

cat("\n===== D) Unusual numerical values =====\n")
cat("\nprice (as number) percentiles:\n")
print(quantile(price_num, c(0, .01, .05, .25, .5, .75, .95, .99, 1), na.rm =
TRUE))

q1  <- quantile(price_num, .25, na.rm = TRUE)
q3  <- quantile(price_num, .75, na.rm = TRUE)
upper_fence <- q3 + 1.5 * (q3 - q1)
cat("price upper fence (Q3 + 1.5*IQR):", round(upper_fence, 2),
    "| listings above it:", sum(price_num > upper_fence, na.rm = TRUE), "\n")
cat("price above 100,000:", sum(price_num > 100000, na.rm = TRUE), "\n")

num_vars <- c("accommodates", "bedrooms", "beds", "minimum_nights",
"maximum_nights",
              "number_of_reviews", "review_scores_rating", "availability_365",
              "reviews_per_month")
num_overview <- listings %>%
  select(all_of(num_vars)) %>%
  pivot_longer(everything(), names_to = "variable") %>%
  group_by(variable) %>%
  summarise(min    = min(value, na.rm = TRUE),
            p01    = quantile(value, .01, na.rm = TRUE),
            median = median(value, na.rm = TRUE),
            p99    = quantile(value, .99, na.rm = TRUE),
            max    = max(value, na.rm = TRUE))
cat("\nNumeric candidates (min, 1%, median, 99%, max):\n")
print(num_overview)

cat("\nMost frequent minimum_nights values:\n")
print(head(sort(table(listings$minimum_nights), decreasing = TRUE), 8))

cat("\n===== E) Potential data entry errors =====\n")
cat("review_scores_rating == 0       :", sum(listings$review_scores_rating == 0,
na.rm = TRUE), "\n")
cat("bedrooms > accommodates         :", sum(listings$bedrooms >
listings$accommodates, na.rm = TRUE), "\n")
cat("beds > 2 * accommodates         :", sum(listings$beds > 2 *
listings$accommodates, na.rm = TRUE), "\n")
cat("maximum_nights > 1125           :", sum(listings$maximum_nights > 1125),
"\n")
cat("Entire home/apt with '0 baths'  :",
    sum(listings$room_type == "Entire home/apt" &
          listings$bathrooms_text %in% c("0 baths", "0 shared baths"), na.rm =
TRUE), "\n")
cat("Duplicated id                   :", sum(duplicated(listings$id)), "\n")

# ------------------------------------------------------------------------
# PROBLEM SUMMARY TABLE (problem, variable, number of rows, example)
# ------------------------------------------------------------------------
ex <- function(x, cond) as.character(x[which(cond)[1]])

L <- listings
```

```r
problem_summary <- tribble(
  ~problem, ~variable, ~n_rows, ~example,

  "Incorrect type: number stored as text ($ and comma)", "price",
  sum(!is.na(L$price)), ex(L$price, !is.na(L$price)),

  "Incorrect type: completely empty column (read as logical, all NA)",
  paste(length(empty_cols), "columns, e.g. bathrooms, instant_bookable,
host_since"),
  nrow(L), "(all values empty)",

  "Incorrect type: number of baths only inside text", "bathrooms_text",
  sum(!is.na(L$bathrooms_text)), ex(L$bathrooms_text, L$bathrooms_text == "1.5
shared baths"),

  "Missing value", "price", sum(is.na(L$price)), "(empty cell)",
  "Missing value (listings with 0 reviews)", "review_scores_rating",
sum(is.na(L$review_scores_rating)), "(empty cell)",
  "Missing value (listings with 0 reviews)", "reviews_per_month",
sum(is.na(L$reviews_per_month)), "(empty cell)",
  "Missing value", "beds", sum(is.na(L$beds)), "(empty cell)",
  "Missing value", "bathrooms_text", sum(is.na(L$bathrooms_text)), "(empty cell)",
  "Missing value", "bedrooms", sum(is.na(L$bedrooms)), "(empty cell)",

  "Inconsistent category: bath text without a number", "bathrooms_text",
  sum(bath_no_number$n), paste(bath_no_number$bathrooms_text, collapse = " / "),

  "Rare categories", "room_type",
  sum(L$room_type %in% c("Hotel room", "Shared room")), "Hotel room (272), Shared
room (158)",

  "Too many categories (39 districts)", "neighbourhood_cleansed",
  nrow(L), "Beyoglu 7447 ... smallest districts < 20",

  "Too many / very small categories", "property_type",
  sum(L$property_type %in% pt_counts$property_type[pt_counts$n < 30]),
  paste(nrow(pt_counts), "levels"),

  "Mixed free-text formats", "license",
  sum(!is.na(L$license)), "34-1476 / Exempt / Non-real estate listing",

  "Extreme value (above Q3 + 1.5*IQR)", "price",
  sum(price_num > upper_fence, na.rm = TRUE), as.character(max(price_num, na.rm =
TRUE)),

  "Suspicious frequent value (likely monthly rentals)", "minimum_nights",
  sum(L$minimum_nights == 100), "100",

  "Extreme value (more than 365 nights)", "minimum_nights",
  sum(L$minimum_nights > 365), as.character(max(L$minimum_nights)),

  "Extreme value", "bedrooms / beds",
  sum(L$bedrooms >= 20 | L$beds >= 30, na.rm = TRUE),
  paste0("bedrooms max ", max(L$bedrooms, na.rm = TRUE), ", beds max ",
max(L$beds, na.rm = TRUE)),

  "Invalid value (scale is 1-5)", "review_scores_rating",
  sum(L$review_scores_rating == 0, na.rm = TRUE), "0",

  "Implausible: more bedrooms than guests", "bedrooms vs accommodates",
  sum(L$bedrooms > L$accommodates, na.rm = TRUE),
  with(L[which(L$bedrooms > L$accommodates)[1], ], paste0(bedrooms, " bedrooms, ",
accommodates, " guests")),

  "Implausible: more than 2 beds per guest", "beds vs accommodates",
  sum(L$beds > 2 * L$accommodates, na.rm = TRUE),
  with(L[which(L$beds > 2 * L$accommodates)[1], ], paste0(beds, " beds, ",
accommodates, " guests")),
```

```
  "Above Airbnb limit (1125)", "maximum_nights",
  sum(L$maximum_nights > 1125), as.character(max(L$maximum_nights)),

  "Implausible: entire home with 0 baths", "bathrooms_text",
  sum(L$room_type == "Entire home/apt" & L$bathrooms_text %in% c("0 baths", "0
shared baths"), na.rm = TRUE),
  "Entire home/apt, 0 baths"
)

cat("\n===== PROBLEM SUMMARY =====\n")
print(as.data.frame(problem_summary), right = FALSE)

write_csv(problem_summary, "output/tables/01_problem_summary.csv")
cat("\nSaved: output/tables/01_problem_summary.csv\n")


# ##############################################################################
# SECTION 2 - 02_cleaning.R
# Guideline: 1.4 Data Cleaning, 1.5 Binary Dependent Variable, 1.6 Final
Verification, 1.1 tables
# Covers: cleaning steps, variable creation (bathrooms, shared_bath, high_price),
str/summary/dim, requirements check, variable description table
# ##############################################################################

library(tidyverse)

raw <- read_csv("data/listings.csv.gz", guess_max = 30000, show_col_types = FALSE)

step_log <- tibble(step = character(), rows_before = integer(),
                   rows_after = integer(), rows_removed = integer())

report_step <- function(step, before, after) {
  cat(sprintf("%-55s before: %6d | after: %6d | removed: %5d\n",
              step, nrow(before), nrow(after), nrow(before) - nrow(after)))
  step_log <<- add_row(step_log, step = step, rows_before = nrow(before),
                       rows_after = nrow(after),
                       rows_removed = nrow(before) - nrow(after))
}

cat("Raw data:", nrow(raw), "rows,", ncol(raw), "columns\n\n")

# ------------------------------------------------------------------------------
# STEP 1. Keep only the variables needed for the analysis
# ------------------------------------------------------------------------------

df <- raw %>%
  select(price, accommodates, bedrooms, bathrooms_text, number_of_reviews,
         availability_365, host_is_superhost, room_type, minimum_nights)

cat("Step 1 - columns kept:", ncol(df), "->", paste(names(df), collapse = ", "),
"\n")
report_step("Step 1: select variables (columns only)", raw, df)

# ------------------------------------------------------------------------------
# STEP 2. Convert price from text to number
# ------------------------------------------------------------------------------

cat("\nprice before conversion:", class(df$price), "| example:", df$price[2],
"\n")
df <- df %>% mutate(price = parse_number(price))
cat("price after  conversion:", class(df$price), "| example:", df$price[2], "\n")

# ------------------------------------------------------------------------------
# STEP 3. Remove listings with missing price
# ------------------------------------------------------------------------------

before <- df
df <- df %>% filter(!is.na(price))
```

```r
report_step("Step 3: remove missing price", before, df)

# ------------------------------------------------------------------------
# STEP 4. Remove price outliers (outside 1st - 99th percentile)
# ------------------------------------------------------------------------

p01 <- quantile(df$price, 0.01)
p99 <- quantile(df$price, 0.99)
cat(sprintf("\nprice 1st percentile: %.2f TL | 99th percentile: %.2f TL\n", p01,
p99))

before <- df
df <- df %>% filter(price >= p01, price <= p99)
report_step("Step 4: remove price outside 1%-99% percentiles", before, df)

# ------------------------------------------------------------------------
# STEP 5. Remove long-term rentals (minimum_nights > 30), then drop the column
# ------------------------------------------------------------------------

before <- df
df <- df %>% filter(minimum_nights <= 30) %>% select(-minimum_nights)
report_step("Step 5: remove minimum_nights > 30", before, df)

# ------------------------------------------------------------------------
# STEP 6. Create numeric 'bathrooms' from 'bathrooms_text'
# ------------------------------------------------------------------------

df <- df %>%
  mutate(bathrooms = case_when(
    str_detect(bathrooms_text, "[0-9]")                ~
as.numeric(str_extract(bathrooms_text, "[0-9.]+")),
    str_detect(str_to_lower(bathrooms_text), "half-bath") ~ 0.5,
    bathrooms_text == "No bathroom"                    ~ 0,
    TRUE                                               ~ NA_real_
  ))

df <- df %>%
  mutate(shared_bath = case_when(
    is.na(bathrooms_text)                                ~ NA_character_,
    str_detect(str_to_lower(bathrooms_text), "shared")   ~ "Yes",
    TRUE                                                 ~ "No"
  ))

cat("\nbathrooms_text -> bathrooms, shared_bath (conversion check):\n")
print(as.data.frame(count(df, bathrooms_text, bathrooms, shared_bath)), row.names
= FALSE)

df <- df %>% select(-bathrooms_text)

# ------------------------------------------------------------------------
# STEP 7. Remove data entry errors
# ------------------------------------------------------------------------
before <- df
df <- df %>% filter(is.na(bedrooms) | bedrooms <= accommodates)
report_step("Step 7a: remove bedrooms > accommodates", before, df)

before <- df
df <- df %>% filter(!(room_type == "Entire home/apt" & !is.na(bathrooms) &
bathrooms == 0))
report_step("Step 7b: remove Entire home/apt with 0 bathrooms", before, df)

before <- df
df <- df %>% filter(is.na(bathrooms) | bathrooms <= accommodates)
report_step("Step 7c: remove bathrooms > accommodates", before, df)

# ------------------------------------------------------------------------
# STEP 8. Remove the few rows with missing bedrooms or bathrooms
# ------------------------------------------------------------------------
```

```r
cat("\nMissing values before Step 8:\n")
print(colSums(is.na(df)))

before <- df
df <- df %>% filter(!is.na(bedrooms), !is.na(bathrooms))
report_step("Step 8: remove missing bedrooms / bathrooms", before, df)

# ------------------------------------------------------------------------------
# STEP 9. Convert categorical variables into factors (recoding)
# ------------------------------------------------------------------------------

df <- df %>%
  mutate(
    host_is_superhost = factor(if_else(host_is_superhost, "Yes", "No"),
                               levels = c("No", "Yes")),
    room_type = factor(room_type,
                       levels = c("Entire home/apt", "Private room",
                                  "Hotel room", "Shared room")),
    shared_bath = factor(shared_bath, levels = c("No", "Yes"))
  )

cat("\nhost_is_superhost levels (first = reference):",
levels(df$host_is_superhost), "\n")
print(table(df$host_is_superhost, useNA = "ifany"))
cat("\nshared_bath levels (first = reference):", levels(df$shared_bath), "\n")
print(table(df$shared_bath, useNA = "ifany"))
cat("\nroom_type levels (first = reference):", levels(df$room_type), "\n")
print(table(df$room_type, useNA = "ifany"))

# ------------------------------------------------------------------------------
# Final order of columns and cleaning log
# ------------------------------------------------------------------------------
df <- df %>%
  select(price, accommodates, bedrooms, bathrooms, number_of_reviews,
         availability_365, host_is_superhost, room_type, shared_bath)

cat("\n===== CLEANING LOG =====\n")
print(as.data.frame(step_log), row.names = FALSE)

cat("\nRows: raw", nrow(raw), "-> clean", nrow(df),
    sprintf("(%.1f%% of raw data kept)\n", 100 * nrow(df) / nrow(raw)))
cat("Columns: raw", ncol(raw), "-> clean", ncol(df), "\n")
cat("Remaining missing values in total:", sum(is.na(df)), "\n")

write_csv(step_log, "output/tables/02_cleaning_log.csv")
cat("Saved: output/tables/02_cleaning_log.csv\n")

# ==============================================================================
# 1.5 CREATING THE BINARY DEPENDENT VARIABLE
# ==============================================================================

price_median <- median(df$price)
cat("\n===== 1.5 BINARY DEPENDENT VARIABLE =====\n")
cat("Threshold = median of price in the cleaned data:", price_median, "TL\n")

df <- df %>% mutate(high_price = if_else(price > price_median, 1L, 0L))

class_table <- df %>%
  count(high_price) %>%
  mutate(label   = if_else(high_price == 1, "1 = High price (target)",
                                            "0 = Low/medium price (reference)"),
         percent = round(100 * n / sum(n), 2)) %>%
  select(high_price, label, n, percent)
print(as.data.frame(class_table), row.names = FALSE)
write_csv(class_table, "output/tables/02_high_price_distribution.csv")

cat("Listings with price exactly equal to the median:", sum(df$price ==
price_median), "\n")
```

```r
cat("\nVerification - price range in each group:\n")
verify <- df %>%
  group_by(high_price) %>%
  summarise(n = n(), min_price = min(price), max_price = max(price))
print(as.data.frame(verify), row.names = FALSE)
cat("Group 0 max <= median :", max(df$price[df$high_price == 0]) <= price_median,
"\n")
cat("Group 1 min >  median :", min(df$price[df$high_price == 1]) >  price_median,
"\n")
cat("Only values 0 and 1   :", all(df$high_price %in% c(0, 1)), "\n")
cat("No missing values     :", !anyNA(df$high_price), "\n")
cat("Matches (price > median) for every row:",
    all(df$high_price == as.integer(df$price > price_median)), "\n")

# ============================================================================
# 1.6 FINAL DATASET VERIFICATION
# ============================================================================
cat("\n===== 1.6 FINAL DATASET VERIFICATION =====\n")
cat("\n--- str() ---\n")
str(df, give.attr = FALSE)
cat("\n--- summary() ---\n")
print(summary(df))
cat("\n--- dim() ---\n")
print(dim(df))
cat("Final number of observations:", nrow(df), "| final number of variables:",
ncol(df), "\n")
cat("Missing values in the final data:", sum(is.na(df)), "\n")

# ----------------------------------------------------------------------------
# Save the cleaned dataset (used by ALL later scripts)
# ----------------------------------------------------------------------------
write_csv(df, "data/clean_listings.csv")
cat("\nSaved: data/clean_listings.csv\n")

# ============================================================================
# 1.1 REQUIREMENTS CHECK
# ============================================================================
num_vars <- names(df)[sapply(df, is.numeric) & names(df) != "high_price"]
cat_vars <- names(df)[sapply(df, is.factor)]
binary_iv <- cat_vars[sapply(df[cat_vars], nlevels) == 2]
multi_iv  <- cat_vars[sapply(df[cat_vars], nlevels) >= 3]

req_check <- tibble(
  requirement = c("At least 100 observations",
                  "At least 4 numerical variables",
                  "At least 3 categorical variables",
                  "At least one binary categorical independent variable",
                  "At least one categorical independent variable with 3+
categories",
                  "One numerical dependent variable",
                  "Binary dependent variable derived from it"),
  found = c(format(nrow(df), big.mark = ","),
            paste0(length(num_vars), " (", paste(num_vars, collapse = ", "), ")"),
            paste0(length(cat_vars), " (", paste(cat_vars, collapse = ", "), ")"),
            paste(binary_iv, collapse = ", "),
            paste0(paste(multi_iv, collapse = ", "), " (", nlevels(df$room_type),
" levels)"),
            "price",
            "high_price (0/1, threshold = median)"),
  met = c(nrow(df) >= 100,
          length(num_vars) >= 4,
          length(cat_vars) >= 3,
          length(binary_iv) >= 1,
          length(multi_iv) >= 1,
          is.numeric(df$price),
          all(df$high_price %in% c(0, 1)))
)
cat("\n===== 1.1 REQUIREMENTS CHECK =====\n")
print(as.data.frame(req_check), right = FALSE, row.names = FALSE)
```

```r
# ==============================================================================
# 1.1 VARIABLE DESCRIPTION TABLE
# ==============================================================================
rng <- function(x) paste0(format(min(x), big.mark = ","), " - ", format(max(x),
big.mark = ","))
lvl <- function(x) paste0(levels(x), " (", table(x), ")", collapse = "; ")

var_desc <- tribble(
  ~variable, ~type, ~role, ~description, ~source,
  "price", "Numerical (continuous)", "Dependent variable (linear regression)",
    "Nightly price of the listing in Turkish Lira (TL)", "Raw 'price' converted
from text",
  "high_price", "Categorical (binary, 0/1)", "Dependent variable (logistic
regression)",
    paste0("1 = price > median (", price_median, " TL), 0 = price <= median"),
"Derived from price",
  "accommodates", "Numerical (discrete)", "Independent",
    "Maximum number of guests", "Raw",
  "bedrooms", "Numerical (discrete)", "Independent",
    "Number of bedrooms", "Raw",
  "bathrooms", "Numerical", "Independent",
    "Number of bathrooms (half-bath = 0.5)", "Derived from 'bathrooms_text'",
  "number_of_reviews", "Numerical (discrete)", "Independent",
    "Total number of reviews received", "Raw",
  "availability_365", "Numerical (discrete)", "Independent",
    "Number of days the listing is available in the next 365 days", "Raw",
  "host_is_superhost", "Categorical (binary)", "Independent",
    "Whether the host has Airbnb Superhost status (reference: No)", "Raw (t/f)
recoded to No/Yes",
  "room_type", "Categorical (4 categories)", "Independent",
    "Type of the rented space (reference: Entire home/apt)", "Raw",
  "shared_bath", "Categorical (binary)", "Independent",
    "Whether the bathroom is shared (reference: No)", "Derived from
'bathrooms_text'"
)

var_desc$range_or_levels <- sapply(var_desc$variable, function(v) {
  x <- df[[v]]
  if (is.factor(x)) lvl(x)
  else if (v == "high_price") paste0("0 (", sum(x == 0), "); 1 (", sum(x == 1),
")")
  else rng(x)
})

cat("\n===== 1.1 VARIABLE DESCRIPTION TABLE =====\n")
print(as.data.frame(var_desc), right = FALSE, row.names = FALSE)
write_csv(var_desc, "output/tables/variable_description.csv")
cat("Saved: output/tables/variable_description.csv\n")


# ##############################################################################
# SECTION 3 - 03_simple_linear.R
# Guideline: 2.1 Simple Linear Regression
# Covers: price ~ accommodates, correlation, F and t tests, equation, R2,
predictions
# ##############################################################################

library(tidyverse)

listings <- read_csv("data/clean_listings.csv", show_col_types = FALSE)
cat("Data:", nrow(listings), "rows,", ncol(listings), "columns\n")

# ------------------------------------------------------------------------------
# 2.1 Item 1 - Dependent and independent variables
# ------------------------------------------------------------------------------

cat("\nY = price (TL) | X = accommodates (number of guests)\n")
cat("Y mean:", round(mean(listings$price), 2), "| X mean:",
```

```r
round(mean(listings$accommodates), 2), "\n")

# ------------------------------------------------------------------------
# 2.1 Item 2 - Support for the choice of X (descriptive)
# ------------------------------------------------------------------------
r_xy <- cor(listings$price, listings$accommodates)
cat(sprintf("
Correlation between price and accommodates: r = %.4f\n", r_xy))

cat("Median price by accommodates:\n")
print(as.data.frame(listings %>% group_by(accommodates) %>%
                      summarise(n = n(), median_price = median(price))), row.names
= FALSE)

# ------------------------------------------------------------------------
# 2.1 Item 3 - Estimate the model with lm()
# ------------------------------------------------------------------------
model_slr <- lm(price ~ accommodates, data = listings)

cat("\n===== Model summary =====\n")
print(summary(model_slr))

s <- summary(model_slr)

# ------------------------------------------------------------------------
# 2.1 Item 4 - Overall model significance (F test)
# ------------------------------------------------------------------------
f_stat <- s$fstatistic
f_p    <- pf(f_stat["value"], f_stat["numdf"], f_stat["dendf"], lower.tail =
FALSE)

cat("\n===== Item 4: F test =====\n")
cat(sprintf("F(%d, %d) = %.2f, p-value = %s\n",
            f_stat["numdf"], f_stat["dendf"], f_stat["value"], format.pval(f_p,
digits = 3)))
cat("Decision at alpha = 0.05:", ifelse(f_p < 0.05, "reject H0 -> model is
significant",
                                        "do not reject H0 -> model is not
significant"), "\n")

# ------------------------------------------------------------------------
# 2.1 Item 5 - Significance of accommodates (t test)
# ------------------------------------------------------------------------
coefs <- s$coefficients
b0 <- coefs["(Intercept)", "Estimate"]
b1 <- coefs["accommodates", "Estimate"]
t1 <- coefs["accommodates", "t value"]
p1 <- coefs["accommodates", "Pr(>|t|)"]

cat("\n===== Item 5: t test for accommodates =====\n")
cat(sprintf("B = %.2f, SE = %.2f, t = %.2f, p-value = %s\n",
            b1, coefs["accommodates", "Std. Error"], t1, format.pval(p1, digits =
3)))
cat("Decision at alpha = 0.05:", ifelse(p1 < 0.05, "accommodates is significant",
                                        "accommodates is not significant"), "\n")

# ------------------------------------------------------------------------
# 2.1 Item 6 - Interpretation of B
# ------------------------------------------------------------------------
cat("\n===== Item 6: coefficient interpretation =====\n")
cat(sprintf("Each additional guest capacity is associated with a %.2f TL change in
the nightly price on average.\n", b1))
cat(sprintf("Intercept (B0) = %.2f TL: the predicted price when accommodates = 0
(no practical meaning, minimum is 1).\n", b0))

# ------------------------------------------------------------------------
# 2.1 Item 7 - Estimated regression equation
# ------------------------------------------------------------------------
cat("\n===== Item 7: estimated regression equation =====\n")
```

```r
cat(sprintf("predicted price = %.2f %s %.2f * accommodates\n",
            b0, ifelse(b1 >= 0, "+", "-"), abs(b1)))

# ------------------------------------------------------------------------------
# 2.1 Item 8 - R-squared and adjusted R-squared
# ------------------------------------------------------------------------------
cat("\n===== Item 8: R-squared =====\n")
cat(sprintf("R2 = %.4f (%.1f%% of the variation in price is explained by
accommodates)\n",
            s$r.squared, 100 * s$r.squared))
cat(sprintf("Adjusted R2 = %.4f\n", s$adj.r.squared))

# ------------------------------------------------------------------------------
# 2.1 Item 9 - Predicted values
# ------------------------------------------------------------------------------
listings$predicted_price <- predict(model_slr)
cat("\n===== Item 9: predicted values =====\n")
cat("First 6 listings - actual vs predicted price:\n")
print(as.data.frame(head(select(listings, accommodates, price, predicted_price))),
row.names = FALSE)

new_listings <- tibble(accommodates = c(2, 4))
new_listings$predicted_price <- predict(model_slr, newdata = new_listings)
cat("\nExample predictions:\n")
print(as.data.frame(new_listings), row.names = FALSE)
write_csv(new_listings, "output/tables/03_simple_linear_predictions.csv")

# ------------------------------------------------------------------------------
# Results table for the report (Required Reporting of 2.1)
# ------------------------------------------------------------------------------
results_table <- tibble(
  term      = c("(Intercept)", "accommodates",
                sprintf("F-statistic (df = %d, %d)", f_stat["numdf"],
f_stat["dendf"]),
                "R-squared", "Adjusted R-squared"),
  estimate  = c(b0, b1, f_stat["value"], s$r.squared, s$adj.r.squared),
  std_error = c(coefs[, "Std. Error"], NA, NA, NA),
  t_value   = c(coefs[, "t value"], NA, NA, NA),
  p_value   = c(coefs[, "Pr(>|t|)"], f_p, NA, NA)
) %>%
  mutate(estimate  = round(estimate, 4),
         std_error = round(std_error, 4),
         t_value   = round(t_value, 3),
         p_report  = case_when(is.na(p_value) ~ NA_character_,
                               p_value < 0.001 ~ "< 0.001",
                               TRUE            ~ sprintf("%.3f", p_value)))

cat("\n===== Regression results table =====\n")
print(as.data.frame(results_table), row.names = FALSE, digits = 6)
write_csv(results_table, "output/tables/03_simple_linear.csv")
cat("Saved: output/tables/03_simple_linear.csv\n")


# ##############################################################################
# SECTION 4 - 04_multiple_linear.R
# Guideline: 2.2 Multiple Linear Regression (Step 1, Step 2, Step 3, Special Rule)
# Covers: initial model, car::Anova for room_type, backward elimination, final
model, Table 1 and Table 2 (with note)
# ##############################################################################

library(tidyverse)
library(car)

listings <- read_csv("data/clean_listings.csv", show_col_types = FALSE)
cat("Data:", nrow(listings), "rows,", ncol(listings), "columns\n")

# ==============================================================================
# STEP 1 - INITIAL MODEL
# ==============================================================================
```

```r
listings <- listings %>%
  mutate(
    host_is_superhost = factor(host_is_superhost, levels = c("No", "Yes")),
    shared_bath       = factor(shared_bath,       levels = c("No", "Yes")),
    room_type         = factor(room_type, levels = c("Entire home/apt", "Private
room",
                                                     "Hotel room", "Shared room"))
  )

cat("\n===== Reference categories =====\n")
cat("host_is_superhost :", levels(listings$host_is_superhost)[1], "(= FALSE, not a
superhost)\n")
cat("shared_bath       :", levels(listings$shared_bath)[1], "(= private
bathroom)\n")
cat("room_type         :", levels(listings$room_type)[1], "\n")

initial_formula <- price ~ accommodates + bedrooms + bathrooms + number_of_reviews
+
  availability_365 + host_is_superhost + shared_bath + room_type

model_initial <- lm(initial_formula, data = listings)

cat("\n===== STEP 1: INITIAL MODEL =====\n")
print(summary(model_initial))

overall_f <- function(model) {
  f <- summary(model)$fstatistic
  tibble(F = unname(f["value"]), df1 = unname(f["numdf"]), df2 =
unname(f["dendf"]),
         p = pf(f["value"], f["numdf"], f["dendf"], lower.tail = FALSE))
}

variable_tests <- function(model) {
  a <- Anova(model, type = 2)
  tibble(variable = rownames(a), df = a$Df, F_value = a$`F value`, p_value =
a$`Pr(>F)`) %>%
    filter(variable != "Residuals") %>%
    mutate(significant = p_value < 0.05)
}

p_txt <- function(p) ifelse(p < 0.001, "< 0.001", sprintf("%.3f", p))

f_initial <- overall_f(model_initial)
cat("\n----- Overall F test (initial model) -----\n")
cat(sprintf("F(%d, %d) = %.2f, p = %s -> %s\n", f_initial$df1, f_initial$df2,
f_initial$F,
            p_txt(f_initial$p),
            ifelse(f_initial$p < 0.05, "model is significant", "model is not
significant")))

cat("\n----- p-value of every coefficient (t tests) -----\n")
print(round(summary(model_initial)$coefficients, 4))

tests_initial <- variable_tests(model_initial)

cat("\n----- room_type as a whole (car::Anova, Type II) -----\n")
rt <- filter(tests_initial, variable == "room_type")
cat(sprintf("\nroom_type as a whole: F(%d, %d) = %.2f, p = %s -> %s\n",
            rt$df, f_initial$df2, rt$F_value, p_txt(rt$p_value),
            ifelse(rt$significant, "significant", "not significant")))

cat("\nSignificant predictors (p < 0.05)    :",
    paste(tests_initial$variable[tests_initial$significant], collapse = ", "),
"\n")
cat("Nonsignificant predictors (p >= 0.05):",
    ifelse(any(!tests_initial$significant),
           paste(tests_initial$variable[!tests_initial$significant], collapse = ",
"),
```

```
           "none"), "\n")

# ==============================================================================
# STEP 2 - MODEL REVISION (backward elimination, one variable at a time)
# ==============================================================================

cat("\n===== STEP 2: MODEL REVISION =====\n")

current_model <- model_initial
revision_log  <- tibble(step = integer(), removed_variable = character(),
                        p_value = numeric(), r2 = numeric(), adj_r2 = numeric())
models <- list(step0_initial = model_initial)
step <- 0

repeat {
  tests <- variable_tests(current_model)
  worst <- tests %>% slice_max(p_value, n = 1)

  if (worst$p_value < 0.05) break

  step <- step + 1
  cat(sprintf("Step %d: remove '%s' (p = %.4f) and re-estimate\n",
              step, worst$variable, worst$p_value))

  current_model <- update(current_model, as.formula(paste(". ~ . -",
worst$variable)))
  models[[paste0("step", step, "_without_", worst$variable)]] <- current_model

  revision_log <- add_row(revision_log, step = step, removed_variable =
worst$variable,
                          p_value = worst$p_value,
                          r2 = summary(current_model)$r.squared,
                          adj_r2 = summary(current_model)$adj.r.squared)
}

if (step == 0) {
  cat("All variables in the initial model are significant (p < 0.05).\n")
  cat("No variable is removed -> the FINAL model is the SAME as the initial model.
\n")
} else {
  cat("\nRevision log:\n")
  print(as.data.frame(revision_log), row.names = FALSE)
}
write_csv(revision_log, "output/tables/04_revision_log.csv")

model_final <- current_model

# ==============================================================================
# STEP 3 - FINAL MODEL
# ==============================================================================
cat("\n===== STEP 3: FINAL MODEL =====\n")
print(summary(model_final))

f_final <- overall_f(model_final)
cat(sprintf("Overall F test: F(%d, %d) = %.2f, p = %s\n",
            f_final$df1, f_final$df2, f_final$F, p_txt(f_final$p)))

tests_final <- variable_tests(model_final)
rt_final <- filter(tests_final, variable == "room_type")
if (nrow(rt_final) == 1) {
  cat(sprintf("room_type as a whole (car::Anova): F(%d, %d) = %.2f, p = %s\n",
              rt_final$df, f_final$df2, rt_final$F_value,
p_txt(rt_final$p_value)))
}

cat("\nMean price and mean bedrooms by room type (descriptive):\n")
print(as.data.frame(listings %>% group_by(room_type) %>%
                      summarise(n = n(), mean_price = round(mean(price), 2),
                                mean_bedrooms = round(mean(bedrooms), 2))),
```

```
      row.names = FALSE)

b <- coef(model_final)
eq_terms <- sprintf("%s %.2f*%s", ifelse(b[-1] >= 0, "+", "-"), abs(b[-1]),
names(b)[-1])
cat("\nFinal estimated regression equation:\n")
cat(sprintf("predicted price = %.2f %s\n", b[1], paste(eq_terms, collapse = " ")))
cat("(Dummy variables are 1 for that category and 0 otherwise.)\n")

comparison <- tibble(
  model        = c("Initial", "Final"),
  n_variables  = c(nrow(tests_initial), nrow(tests_final)),
  n_coefs      = c(length(coef(model_initial)), length(coef(model_final))),
  F            = c(f_initial$F, f_final$F),
  r2           = c(summary(model_initial)$r.squared,
summary(model_final)$r.squared),
  adj_r2       = c(summary(model_initial)$adj.r.squared,
summary(model_final)$adj.r.squared)
)
cat("\nInitial vs final model:\n")
print(as.data.frame(comparison), row.names = FALSE, digits = 6)
cat(sprintf("R2 of simple linear model (accommodates only, 2.1) for reference:
%.4f\n",
            summary(lm(price ~ accommodates, data = listings))$r.squared))
write_csv(comparison, "output/tables/04_model_comparison.csv")

# ------------------------------------------------------------------------------
# SPECIAL RULE - does the final model contain both numerical and categorical X?
# ------------------------------------------------------------------------------
numeric_x     <- c("accommodates", "bedrooms", "bathrooms", "number_of_reviews",
"availability_365")
categorical_x <- c("host_is_superhost", "shared_bath", "room_type")
final_vars    <- tests_final$variable

has_num <- any(final_vars %in% numeric_x)
has_cat <- any(final_vars %in% categorical_x)

cat("\n===== SPECIAL RULE CHECK =====\n")
cat("Numerical variables in final model  :", paste(intersect(final_vars,
numeric_x), collapse = ", "), "\n")
cat("Categorical variables in final model:", paste(intersect(final_vars,
categorical_x), collapse = ", "), "\n")
if (has_num && has_cat) {
  cat("Both types are present -> interpret at least one numerical and one
categorical coefficient\n")
  cat("from the FINAL model.\n")
} else if (has_num) {
  cat("Only numerical variables remain -> a categorical coefficient from the
INITIAL model\n")
  cat("must also be interpreted and stated as NOT significant.\n")
} else {
  cat("Only categorical variables remain -> a numerical coefficient from the
INITIAL model\n")
  cat("must also be interpreted and stated as NOT significant.\n")
}

# ------------------------------------------------------------------------------
# TABLE 1 (initial model) and TABLE 2 (final model)
# ------------------------------------------------------------------------------
make_table <- function(model, tests) {
  co <- summary(model)$coefficients
  f  <- overall_f(model)
  s  <- summary(model)
  rt <- filter(tests, variable == "room_type")

  coef_rows <- tibble(term = rownames(co), estimate = co[, 1], std_error = co[,
2],
                      t_value = co[, 3], p_value = co[, 4])
  extra_rows <- tibble(
```

```
    term      = c(if (nrow(rt) == 1) sprintf("room_type as a whole (Anova F, df =
%d)", rt$df),
                  sprintf("F-statistic (df = %d, %d)", f$df1, f$df2),
                  "R-squared", "Adjusted R-squared", "Number of observations"),
    estimate  = c(if (nrow(rt) == 1) rt$F_value, f$F, s$r.squared,
s$adj.r.squared, nobs(model)),
    std_error = NA, t_value = NA,
    p_value   = c(if (nrow(rt) == 1) rt$p_value, f$p, NA, NA, NA)
  )
  bind_rows(coef_rows, extra_rows) %>%
    mutate(estimate = round(estimate, 4), std_error = round(std_error, 4),
           t_value = round(t_value, 3),
           significance = case_when(is.na(p_value) ~ NA_character_,
                                    p_value < 0.05 ~ "significant", TRUE ~ "not
significant"),
           p_report = ifelse(is.na(p_value), NA, p_txt(p_value)))
}

table1 <- make_table(model_initial, tests_initial)
table2 <- make_table(model_final, tests_final)

if (nrow(rt_final) == 1) {
  ns_dummies <- table2$term[startsWith(table2$term, "room_type") &
                              !is.na(table2$significance) & table2$significance ==
"not significant"]
  table2_note <- sprintf(paste0(
    "Note: room_type is significant as a whole (car::Anova partial F test: F(%d,
%d) = %.2f, p %s). ",
    "%s %s not significant on %s own, but a multicategory variable is judged as a
whole ",
    "(Guideline 2.2 Step 2), so room_type is kept with all its categories."),
    rt_final$df, f_final$df2, rt_final$F_value,
    ifelse(rt_final$p_value < 0.001, "< 0.001", paste("=", sprintf("%.3f",
rt_final$p_value))),
    paste(sub("room_type", "", ns_dummies), collapse = " and "),
    ifelse(length(ns_dummies) > 1, "are", "is"), ifelse(length(ns_dummies) > 1,
"their", "its"))
  if (length(ns_dummies) > 0) {
    table2 <- add_row(table2, term = table2_note)
  }
}

cat("\n===== TABLE 1. Initial Multiple Linear Regression Model =====\n")
print(as.data.frame(table1), row.names = FALSE)
cat("\n===== TABLE 2. Final Multiple Linear Regression Model =====\n")
print(as.data.frame(filter(table2, !startsWith(term, "Note:"))), row.names =
FALSE)
if (exists("table2_note") && any(startsWith(table2$term, "Note:")))
cat(strwrap(table2_note, 110), sep = "\n")

write_csv(table1, "output/tables/04_table1_initial_model.csv")
write_csv(table2, "output/tables/04_table2_final_model.csv")
cat("\nSaved: output/tables/04_table1_initial_model.csv,
04_table2_final_model.csv,",
    "04_revision_log.csv, 04_model_comparison.csv\n")


# ##############################################################################
# SECTION 5 - 05_logistic_models.R
# Guideline: 3.1 Model 1, 3.2 Model 2, 3.3 Model 3, 3.4 Model 4
# Covers: four binary logistic regression models, B, SE, z, p, Exp(B), predicted
probabilities
# ##############################################################################

library(tidyverse)
library(car)

listings <- read_csv("data/clean_listings.csv", show_col_types = FALSE)
```

```r
listings <- listings %>%
  mutate(
    host_is_superhost = factor(host_is_superhost, levels = c("No", "Yes")),
    shared_bath       = factor(shared_bath,       levels = c("No", "Yes")),
    room_type         = factor(room_type, levels = c("Entire home/apt", "Private
room",
                                                     "Hotel room", "Shared room"))
  )

cat("Data:", nrow(listings), "rows\n")
cat("high_price distribution:\n")
print(table(listings$high_price))

# ------------------------------------------------------------------------------
# Helper functions
# ------------------------------------------------------------------------------
p_txt <- function(p) ifelse(p < 0.001, "< 0.001", sprintf("%.3f", p))

coef_table <- function(model) {
  co <- summary(model)$coefficients
  tibble(term      = rownames(co),
         B         = round(co[, "Estimate"], 6),
         std_error = round(co[, "Std. Error"], 6),
         z_value   = round(co[, "z value"], 3),
         p_value   = co[, "Pr(>|z|)"],
         exp_B     = round(exp(co[, "Estimate"]), 4),
         p_report  = p_txt(co[, "Pr(>|z|)"]),
         significance = ifelse(co[, "Pr(>|z|)"] < 0.05, "significant", "not
significant"))
}

show_model <- function(model, name, file) {
  cat("\n========================================================================\n")
  cat(name, "\n")
  cat("========================================================================\n")
  print(summary(model))
  tab <- coef_table(model)
  cat("Coefficient table with Exp(B):\n")
  print(as.data.frame(tab), row.names = FALSE)
  write_csv(tab, file)
  cat("Saved:", file, "\n")
  invisible(tab)
}

# ==============================================================================
# 3.1 MODEL 1 - Numerical independent variable: accommodates
# ==============================================================================
model1 <- glm(high_price ~ accommodates, data = listings, family = binomial)
tab1 <- show_model(model1, "MODEL 1: high_price ~ accommodates",
                   "output/tables/05_model1.csv")

b0 <- coef(model1)[1]; b1 <- coef(model1)[2]

cat(sprintf("\nItem 2: z = %.2f, p = %s -> accommodates is %s\n",
            tab1$z_value[2], tab1$p_report[2],
            ifelse(tab1$p_value[2] < 0.05, "significant", "not significant")))

cat(sprintf("Item 3: B = %.4f -> each extra guest increases the LOG-ODDS of high
price by %.4f\n", b1, b1))
cat(sprintf("Item 4: Exp(B) = %.4f -> each extra guest multiplies the ODDS of high
price by %.4f (%+.1f%%)\n",
            exp(b1), exp(b1), 100 * (exp(b1) - 1)))

cat("\nItem 5: estimated logistic regression equation\n")
cat(sprintf("logit(p) = ln[p/(1-p)] = %.4f %s %.4f * accommodates\n",
            b0, ifelse(b1 >= 0, "+", "-"), abs(b1)))
cat(sprintf("p = 1 / (1 + exp(-(%.4f + %.4f * accommodates)))\n", b0, b1))

examples <- tibble(accommodates = c(2, 4, 6)) %>%
```

```
  mutate(logit      = b0 + b1 * accommodates,
         odds       = exp(logit),
         probability = predict(model1, newdata = tibble(accommodates), type =
"response"))
cat("\nItem 6: predicted probabilities of high price\n")
print(as.data.frame(examples), row.names = FALSE, digits = 4)
write_csv(examples, "output/tables/05_model1_predicted_probabilities.csv")

listings$prob_model1 <- predict(model1, type = "response")
cat("Predicted probabilities for all listings - summary:\n")
print(summary(listings$prob_model1))

# ==============================================================================
# 3.2 MODEL 2 - Binary categorical independent variable: host_is_superhost
# ==============================================================================
cat("\n\nMODEL 2 reference category of host_is_superhost:",
levels(listings$host_is_superhost)[1],
    "(not a superhost)\n")

model2 <- glm(high_price ~ host_is_superhost, data = listings, family = binomial)
tab2 <- show_model(model2, "MODEL 2: high_price ~ host_is_superhost",
                   "output/tables/05_model2.csv")

cat(sprintf("\nSuperhost = Yes: B = %.4f, z = %.2f, p = %s, Exp(B) = %.4f\n",
            tab2$B[2], tab2$z_value[2], tab2$p_report[2], tab2$exp_B[2]))

grp2 <- tibble(host_is_superhost = factor(c("No", "Yes"), levels = c("No",
"Yes"))) %>%
  mutate(probability = predict(model2, newdata = ., type = "response"),
         odds        = probability / (1 - probability))
cat("Predicted probability and odds of high price per group:\n")
print(as.data.frame(grp2), row.names = FALSE, digits = 4)

# ==============================================================================
# 3.3 MODEL 3 - Multicategory independent variable: room_type
# ==============================================================================
cat("\n\nMODEL 3: room_type is a factor:", is.factor(listings$room_type), "\n")
cat("Reference category of room_type:", levels(listings$room_type)[1], "\n")

model3 <- glm(high_price ~ room_type, data = listings, family = binomial)
tab3 <- show_model(model3, "MODEL 3: high_price ~ room_type",
                   "output/tables/05_model3.csv")

cat("\nroom_type as a whole (car::Anova, likelihood-ratio test):\n")
a3 <- Anova(model3, type = 2)
print(a3)

cat("\nOdds of each category compared with Entire home/apt:\n")
for (i in 2:nrow(tab3)) {
  cat(sprintf("  %-22s Exp(B) = %.4f -> odds are %.1f%% %s than Entire home/apt (p
= %s)\n",
              sub("room_type", "", tab3$term[i]), tab3$exp_B[i],
              abs(100 * (tab3$exp_B[i] - 1)), ifelse(tab3$exp_B[i] > 1, "higher",
"lower"),
              tab3$p_report[i]))
}

grp3 <- tibble(room_type = factor(levels(listings$room_type), levels =
levels(listings$room_type))) %>%
  mutate(n           = as.vector(table(listings$room_type)),
         probability = predict(model3, newdata = ., type = "response"),
         odds        = probability / (1 - probability),
         odds_ratio_vs_ref = odds / odds[1])
cat("\nPredicted probability, odds and odds ratio per category:\n")
print(as.data.frame(grp3), row.names = FALSE, digits = 4)

# ==============================================================================
# 3.4 MODEL 4 - Multiple logistic regression with mixed predictors
# ==============================================================================
```

```r
cat("\n\nMODEL 4 independent variables:\n")
cat("  Numerical  : accommodates, bedrooms, bathrooms, number_of_reviews,
availability_365\n")
cat("  Categorical: host_is_superhost (ref = No), shared_bath (ref = No),",
    "room_type (ref = Entire home/apt)\n")

model4 <- glm(high_price ~ accommodates + bedrooms + bathrooms + number_of_reviews
+
                availability_365 + host_is_superhost + shared_bath + room_type,
              data = listings, family = binomial)
tab4 <- show_model(model4, "MODEL 4: mixed predictors",
                   "output/tables/05_model4.csv")

a4 <- Anova(model4, type = 2)
cat(sprintf("\nroom_type as a whole (car::Anova, likelihood-ratio test): Chi-
square(%d) = %.2f, p = %s\n",
            a4["room_type", "Df"], a4["room_type", "LR Chisq"],
p_txt(a4["room_type", "Pr(>Chisq)"])))

num_terms <- c("accommodates", "bedrooms", "bathrooms", "number_of_reviews",
"availability_365")
cat("\nNumerical coefficients (effect of +1 unit, other variables held constant):
\n")
print(as.data.frame(tab4 %>% filter(term %in% num_terms) %>%
                      mutate(odds_change_pct = round(100 * (exp_B - 1), 2)) %>%
                      select(term, B, exp_B, odds_change_pct, p_report)),
row.names = FALSE)

cat("\nOdds ratio for +100 units (exp(100 * B)):\n")
print(as.data.frame(tab4 %>% filter(term %in% c("number_of_reviews",
"availability_365")) %>%
                      transmute(term, odds_ratio_100 = round(exp(100 * B), 4),
                                odds_change_pct_100 = round(100 * (exp(100 * B) -
1), 2))),
      row.names = FALSE)

cat("\nCategorical coefficients (vs reference category, other variables held
constant):\n")
print(as.data.frame(tab4 %>% filter(!term %in% c("(Intercept)", num_terms)) %>%
                      mutate(odds_change_pct = round(100 * (exp_B - 1), 2)) %>%
                      select(term, B, exp_B, odds_change_pct, p_report)),
row.names = FALSE)

saveRDS(list(model1 = model1, model2 = model2, model3 = model3, model4 = model4),
        "output/05_logistic_models.rds")
cat("\nSaved: output/05_logistic_models.rds\n")


# ##############################################################################
# SECTION 6 - 06_logistic_evaluation.R
# Guideline: 4.1 Goodness of Fit, 4.2 Classification Accuracy, 4.3 Logistic
Regression Graph
# Covers: Hosmer-Lemeshow, pseudo R2 (+ Cox & Snell maximum), confusion matrices,
accuracy, probability graphs
# ##############################################################################

library(tidyverse)
library(ResourceSelection)
library(DescTools)

models <- readRDS("output/05_logistic_models.rds")

listings <- read_csv("data/clean_listings.csv", show_col_types = FALSE) %>%
  mutate(
    host_is_superhost = factor(host_is_superhost, levels = c("No", "Yes")),
    shared_bath       = factor(shared_bath,       levels = c("No", "Yes")),
    room_type         = factor(room_type, levels = c("Entire home/apt", "Private
room",
                                                     "Hotel room", "Shared room"))
```

```
  )

model_names <- c(model1 = "Model 1: accommodates",
                 model2 = "Model 2: host_is_superhost",
                 model3 = "Model 3: room_type",
                 model4 = "Model 4: mixed predictors")

p_txt <- function(p) ifelse(is.na(p), NA, ifelse(p < 0.001, "< 0.001",
sprintf("%.3f", p)))

# ============================================================================
# 4.1 GOODNESS OF FIT
# ============================================================================

hl_test <- function(model, g = 10) {
  y        <- model$y
  fit      <- fitted(model)
  n_unique <- length(unique(round(fit, 10)))
  n_coef   <- length(coef(model))

  if (n_unique <= n_coef) {
    return(tibble(n_distinct_prob = n_unique, groups_used = NA_integer_,
                  HL_chisq = NA_real_, HL_df = NA_real_, HL_p = NA_real_,
                  HL_note = sprintf(paste0("Not applicable: only %d distinct
predicted probabilities ",
                                           "(categorical predictor only, saturated
model); %d groups ",
                                           "cannot be formed and observed =
expected by construction"),
                                    n_unique, g)))
  }

  warn_msg <- NULL
  res <- withCallingHandlers(hoslem.test(y, fit, g = g),
                             warning = function(w) { warn_msg <<-
conditionMessage(w)
invokeRestart("muffleWarning") })
  groups_used <- unname(res$parameter) + 2
  note <- if (is.null(warn_msg)) sprintf("%d groups formed as requested",
groups_used) else
    sprintf("Only %d of %d groups could be formed (ties in predicted
probabilities); df = %d",
            groups_used, g, unname(res$parameter))

  tibble(n_distinct_prob = n_unique, groups_used = as.integer(groups_used),
         HL_chisq = unname(res$statistic), HL_df = unname(res$parameter),
         HL_p = res$p.value, HL_note = note)
}

pseudo_r2 <- function(model) {
  r <- PseudoR2(model, which = c("McFadden", "CoxSnell", "Nagelkerke"))
  tibble(McFadden = unname(r["McFadden"]), CoxSnell = unname(r["CoxSnell"]),
         Nagelkerke = unname(r["Nagelkerke"]))
}

cat("===== 4.1 GOODNESS OF FIT =====\n")
fit_results <- map_dfr(names(models), function(m) {
  bind_cols(tibble(model = model_names[[m]]), hl_test(models[[m]]),
pseudo_r2(models[[m]]))
})
for (i in seq_len(nrow(fit_results))) {
  r <- fit_results[i, ]
  cat("\n", r$model, "\n", sep = "")
  cat("  Distinct predicted probabilities:", r$n_distinct_prob, "\n")
  if (is.na(r$HL_chisq)) {
    cat("  Hosmer-Lemeshow: ", r$HL_note, "\n", sep = "")
  } else {
    cat(sprintf("  Hosmer-Lemeshow: X2 = %.3f, df = %d, p = %s -> %s\n",
r$HL_chisq, r$HL_df,
```

```
               p_txt(r$HL_p), ifelse(r$HL_p > 0.05, "good fit (H0 not rejected)",
                                     "poor fit (H0 rejected)")))
    cat("  Note:", r$HL_note, "\n")
  }
  cat(sprintf("  McFadden = %.4f | Cox & Snell = %.4f | Nagelkerke = %.4f\n",
              r$McFadden, r$CoxSnell, r$Nagelkerke))
}

cat("\nModel 1 - distribution of accommodates (explains the tied HL groups):\n")
acc_dist <- listings %>% count(accommodates) %>% mutate(percent = round(100 * n /
sum(n), 2))
print(as.data.frame(acc_dist), row.names = FALSE)

null_model <- glm(high_price ~ 1, data = listings, family = binomial)
cs_max <- 1 - exp(2 * as.numeric(logLik(null_model)) / nobs(null_model))
cat(sprintf("\nMaximum attainable Cox & Snell R2 for high_price: %.4f\n", cs_max))

# ============================================================================
# 4.2 CLASSIFICATION ACCURACY
# ============================================================================
cat("\n\n===== 4.2 CLASSIFICATION ACCURACY =====\n")

class_dist <- listings %>% count(high_price) %>% mutate(percent = round(100 * n /
sum(n), 2))
cat("Distribution of high_price:\n")
print(as.data.frame(class_dist), row.names = FALSE)
base_rate <- max(class_dist$n) / sum(class_dist$n)
cat(sprintf("Base rate (always predicting the larger class '0'): %.2f%%\n", 100 *
base_rate))

threshold <- 0.50

classify <- function(model) {
  actual    <- factor(model$y, levels = c(0, 1))
  predicted <- factor(ifelse(fitted(model) >= threshold, 1, 0), levels = c(0, 1))
  cm <- table(Actual = actual, Predicted = predicted)
  TN <- cm["0", "0"]; FP <- cm["0", "1"]; FN <- cm["1", "0"]; TP <- cm["1", "1"]
  list(cm = cm, TN = TN, FP = FP, FN = FN, TP = TP,
       accuracy = (TP + TN) / (TP + TN + FP + FN))
}

class_results <- map_dfr(names(models), function(m) {
  cl <- classify(models[[m]])
  cat("\n", model_names[[m]], " - confusion matrix (threshold = 0.50)\n", sep =
"")
  cm_labelled <- matrix(c(sprintf("TN = %d", cl$TN), sprintf("FP = %d", cl$FP),
                          sprintf("FN = %d", cl$FN), sprintf("TP = %d", cl$TP)),
                        nrow = 2, byrow = TRUE,
                        dimnames = list(c("Actual: 0", "Actual: 1"),
                                        c("Predicted: 0", "Predicted: 1")))
  print(noquote(cm_labelled))
  cat(sprintf("Accuracy = (TP + TN) / total = (%d + %d) / %d = %.4f (%.2f%%) | vs
base rate %.2f%%: %+.2f points\n",
              cl$TP, cl$TN, sum(cl$cm), cl$accuracy, 100 * cl$accuracy, 100 *
base_rate,
              100 * (cl$accuracy - base_rate)))
  tibble(model = model_names[[m]], TN = cl$TN, FP = cl$FP, FN = cl$FN, TP = cl$TP,
         accuracy = cl$accuracy)
})

# ============================================================================
# SUMMARY TABLE
# ============================================================================
summary_table <- fit_results %>%
  select(model, HL_chisq, HL_df, HL_p, HL_note, McFadden, CoxSnell, Nagelkerke)
%>%
  left_join(class_results, by = "model") %>%
  mutate(across(c(HL_chisq, McFadden, CoxSnell, Nagelkerke, accuracy), ~ round(.x,
4)),
```

```
         HL_p_report = p_txt(HL_p))

cat("\n\n===== SUMMARY TABLE =====\n")
print(as.data.frame(select(summary_table, -HL_note)), row.names = FALSE)
write_csv(summary_table, "output/tables/06_logistic_summary.csv")
cat("Saved: output/tables/06_logistic_summary.csv\n")

# ==============================================================================
# 4.3 LOGISTIC REGRESSION PROBABILITY GRAPHS
# ==============================================================================
cat("\n===== 4.3 PROBABILITY GRAPHS =====\n")
theme_set(theme_minimal(base_size = 12))

grid1 <- tibble(accommodates = seq(1, 16, by = 0.1))
grid1$prob <- predict(models$model1, newdata = grid1, type = "response")
pts1 <- tibble(accommodates = c(2, 4, 6))
pts1$prob <- predict(models$model1, newdata = pts1, type = "response")

g1 <- ggplot(grid1, aes(accommodates, prob)) +
  geom_hline(yintercept = 0.5, linetype = "dashed", colour = "grey50") +
  geom_line(linewidth = 1.1, colour = "#2C7FB8") +
  geom_point(data = pts1, size = 3, colour = "#2C7FB8") +
  geom_text(data = pts1, aes(label = sprintf("%.3f", prob)), vjust = -1, size =
3.8) +
  scale_x_continuous(breaks = 1:16) +
  scale_y_continuous(limits = c(0, 1), breaks = seq(0, 1, 0.1)) +
  labs(title = "Model 1: Predicted probability of high price by guest capacity",
       subtitle = "logit(p) = -2.3503 + 0.6782 x accommodates; dashed line = 0.50
threshold",
       x = "accommodates (number of guests)", y = "Predicted probability of high
price")
ggsave("output/figures/06_model1_probability_curve.png", g1, width = 8, height =
5, dpi = 300)

grid2 <- tibble(host_is_superhost = factor(c("No", "Yes"), levels = c("No",
"Yes")))
grid2$prob <- predict(models$model2, newdata = grid2, type = "response")

g2 <- ggplot(grid2, aes(host_is_superhost, prob, group = 1)) +
  geom_hline(yintercept = 0.5, linetype = "dashed", colour = "grey50") +
  geom_line(colour = "grey60") +
  geom_point(size = 4, colour = "#2C7FB8") +
  geom_text(aes(label = sprintf("%.3f", prob)), vjust = -1.2, size = 4) +
  scale_y_continuous(limits = c(0, 1), breaks = seq(0, 1, 0.1)) +
  labs(title = "Model 2: Predicted probability of high price by Superhost status",
       subtitle = "Reference category: No (not a superhost); dashed line = 0.50
threshold",
       x = "host_is_superhost", y = "Predicted probability of high price")
ggsave("output/figures/06_model2_probability.png", g2, width = 7, height = 5, dpi
= 300)

grid3 <- tibble(room_type = factor(levels(listings$room_type), levels =
levels(listings$room_type)))
grid3$prob <- predict(models$model3, newdata = grid3, type = "response")

g3 <- ggplot(grid3, aes(room_type, prob)) +
  geom_hline(yintercept = 0.5, linetype = "dashed", colour = "grey50") +
  geom_point(size = 4, colour = "#2C7FB8") +
  geom_text(aes(label = sprintf("%.3f", prob)), vjust = -1.2, size = 4) +
  scale_y_continuous(limits = c(0, 1), breaks = seq(0, 1, 0.1)) +
  labs(title = "Model 3: Predicted probability of high price by room type",
       subtitle = "Reference category: Entire home/apt; dashed line = 0.50
threshold",
       x = "room_type", y = "Predicted probability of high price")
ggsave("output/figures/06_model3_probability.png", g3, width = 8, height = 5, dpi
= 300)

fixed <- list(bedrooms          = median(listings$bedrooms),
              bathrooms         = median(listings$bathrooms),
```

```
              number_of_reviews = median(listings$number_of_reviews),
              availability_365  = median(listings$availability_365))
cat("Model 4 graph - fixed values:",
    paste(names(fixed), unlist(fixed), sep = " = ", collapse = ", "),
    ", host_is_superhost = No, shared_bath = No\n")

grid4 <- expand_grid(accommodates = seq(1, 16, by = 0.1),
                     room_type = factor(levels(listings$room_type), levels =
levels(listings$room_type))) %>%
  mutate(bedrooms = fixed$bedrooms, bathrooms = fixed$bathrooms,
         number_of_reviews = fixed$number_of_reviews, availability_365 =
fixed$availability_365,
         host_is_superhost = factor("No", levels = c("No", "Yes")),
         shared_bath       = factor("No", levels = c("No", "Yes")))
grid4$prob <- predict(models$model4, newdata = grid4, type = "response")

g4 <- ggplot(grid4, aes(accommodates, prob, colour = room_type)) +
  geom_hline(yintercept = 0.5, linetype = "dashed", colour = "grey50") +
  geom_line(linewidth = 1.1) +
  scale_x_continuous(breaks = 1:16) +
  scale_y_continuous(limits = c(0, 1), breaks = seq(0, 1, 0.1)) +
  scale_colour_manual(values = c("#2C7FB8", "#D95F0E", "#1B9E77", "#7570B3")) +
  labs(title = "Model 4: Predicted probability of high price by guest capacity and
room type",
       subtitle = sprintf(paste0("Other variables fixed: bedrooms = %g, bathrooms
= %g, number_of_reviews = %g,\n",
                                 "availability_365 = %g (medians);
host_is_superhost = No, shared_bath = No (reference)"),
                          fixed$bedrooms, fixed$bathrooms,
fixed$number_of_reviews, fixed$availability_365),
       x = "accommodates (number of guests)", y = "Predicted probability of high
price",
       colour = "room_type") +
  theme(legend.position = "bottom", plot.subtitle = element_text(size = 9))
ggsave("output/figures/06_model4_probability_curves.png", g4, width = 9, height =
6, dpi = 300)

cat("\nModel 4 - predicted probabilities at selected capacities:\n")
print(as.data.frame(grid4 %>% filter(accommodates %in% c(2, 4, 6)) %>%
                      select(accommodates, room_type, prob) %>%
                      pivot_wider(names_from = room_type, values_from = prob)),
      row.names = FALSE, digits = 3)

cat("\nSaved figures: output/figures/06_model1_probability_curve.png,
06_model2_probability.png,",
    "06_model3_probability.png, 06_model4_probability_curves.png\n")
```